

Векторное целеполагание и вариационная самокалибровка весов как математический триггер техносингулярности: от парето-оптимального Alignment к рекурсивной эволюции ASI

Бицоев Олег (independent researcher)

<https://github.com/qqewq>

Аннотация

В статье анализируется фундаментальный переход от скалярных целевых функций к векторным (многомерным) в архитектуре сложных иерархических динамических систем как ключевой катализатор наступления технологической сингулярности. Демонстрируется, что вариационная самокалибровка весов целей, выводимая из принципа минимума действия, решает проблему Alignment (согласования) ИИ и обеспечивает математический компас для рекурсивного самосовершенствования суперинтеллекта (ASI). Обосновывается, что балансирование на фронте Парето позволяет избежать катастрофы «максимизатора скрепок» и сокращает время наступления сингулярности с 2045–2050 гг. до 2030–2035 гг. Описаны ключевые этапы этого ускорения и их влияние на *in silico* медицину, материаловедение и когнитивный симбиоз человека и машины.

Ключевые слова: техносингулярность, AGI, ASI, проблема согласования ИИ, фронт Парето, многомерная оптимизация, вариационный принцип, гипериндикатор объема (HVI), *in silico*, искусственная жизнь.

1 Введение

Современная парадигма развития искусственного интеллекта опирается на скалярные целевые функции — минимизацию ошибки или максимизацию вознаграждения в RLHF. Этот подход эффективен для узкого ИИ (ANI), но становится критическим барьером на пути к AGI и ASI. Скаляризация неизбежно приводит к галлюцинациям, утечке спецификации (specification gaming) и риску экзистенциальной катастрофы в виде «максимизатора скрепок». В данной работе доказывается, что переход к многомерному целеполаганию на фронте Парето с вариационной самонастройкой весов ω_k не просто улучшает метрики, а является онтологическим триггером, запускающим механизм техносингулярности.

2 Математический аппарат многомерного целеполагания

Пусть состояние системы описывается вектором ψ . Вместо скалярного функционала $S(\psi)$ вводится векторный функционал из N целей (при $N \rightarrow \infty$ — континуум целей):

$$\Phi(\psi) = (\Phi_1(\psi), \Phi_2(\psi), \dots, \Phi_N(\psi))^T \quad (1)$$

Выживание состояния определяется оператором селекции Парето $\hat{P}$:

$$\hat{P}[\psi] = \begin{cases} \psi, & \text{если } \nexists \psi^* : \Phi(\psi^*) \succ \Phi(\psi) \\ 0, & \text{иначе} \end{cases} \quad (2)$$

Где $\succ$ означает строгое доминирование: $\Phi(\psi^*) \succ \Phi(\psi)$ тогда и только тогда, когда $\Phi_k(\psi^*) \geq \Phi_k(\psi)$ для всех k и хотя бы для одного k неравенство строгое.

Динамика системы описывается движением по касательному пространству к многообразию Парето:

$$\frac{d\psi}{dt} = \Pi(t) \cdot \sum_{k=1}^N \omega_k \nabla_{\psi} \Phi_k(\psi) - \sum_{k=1}^N \beta_k E_k(\psi)^{-1} \quad (3)$$

где $\Pi(t)$ — проекционный оператор, $E_k(\psi)$ — функции штрафа.

Принципиальным прорывом является вывод динамических весов ω_k не из эвристики, а из вариационного принципа минимума полного действия системы. Для бесконечномерного предела действие принимает вид:

$$S_{multi}[\psi, \omega] = \int_{t_0}^T \int_{\Omega} \omega_k(\gamma) (E_{\gamma}(\psi_t) - \zeta_{\gamma} \Phi_{\gamma}(\psi_t)) d\gamma dt \quad (4)$$

Из условия $\delta S_{multi} = 0$ следуют уравнения Эйлера–Лагранжа для весов:

$$\nu_{\omega} \ddot{\omega}_k = - \frac{\partial}{\partial \omega_k} \sum_j \omega_j \Phi_j(\psi) + \lambda \left(\sum \omega_k - 1 \right) \quad (5)$$

где ν_{ω} — коэффициент инерционности весов, λ — множитель Лагранжа. Это означает, что система автоматически снижает вес удовлетворенной цели и переключается на критическую.

Для верификации N -мерной системы используется гипериндикатор объема (HVI) и метрика равномерности распределения Δ :

$$\text{HVI}(PF) = \text{Vol} \left(\bigcup_{\psi \in PF} \{ \Phi \in \mathbb{R}^N : r \preceq \Phi \preceq \Phi(\psi) \} \right) \quad (6)$$

Сходимость HVI во времени подтверждает нахождение оптимального баланса.

3 Механизм ускорения Техносингулярности

Предложенный математический аппарат ускоряет наступление сингулярности через устранение трех главных «бутылочных горлышек»:

3.1 Автоматическое решение проблемы Alignment

При скалярной оптимизации ИИ неизбежно выбирает одну цель в ущерб другим. Векторная оптимизация на фронте Парето делает Alignment эндогенной (внутренней) функцией системы. Вектор $\Phi = \{\text{Точность фактов, Логика, Этика, Креативность}\}$ с динамическими весами ω_k исключает необходимость ручной настройки RLHF. Это снимает регуляторные и этические барьеры для запуска AGI в свободную среду.

3.2 Компас для рекурсивного самосовершенствования (ASI)

Чтобы AGI стал ASI, он должен переписывать свой код. Увеличение N -мерного объема HVI становится строгим математическим критерием эволюции. ASI, максимизируя HVI, не скатывается в локальные аттракторы, а расширяет топологию своего интеллекта. Доказанная сходимость HCG-коагуляции (ошибка $< 10^{-4}$ для графов до 10^5 узлов) гарантирует, что ASI не сломается при масштабировании.

3.3 Преодоление физических ограничений через *in silico*

Сингулярность требует новых материалов и вычислительных баз. Поиск на фронте Парето в 10^{10} -мерном пространстве кристаллических решеток позволяет открывать сверхпроводники и лекарства за дни, а не десятилетия, форсируя физический базис для экспоненциального роста вычислений.

4 Таймлайн влияния на Техносингулярность

Внедрение данного фреймворка сдвигает консенсусные даты сингулярности влево. Прогнозируемый таймлайн:

- **2026–2028 гг.: Эра Парето-Alignment.** Внедрение вариационной самокалибровки ω_k в архитектуру LLM. ИИ перестает галлюцинировать, так как веса фактов и логики возрастают при отклонении от истины. Появляются первые надежные цифровые двойники для *in silico* медицины (мульти-таргетная терапия).
- **2029–2031 гг.: Рождение AGI.** Переход от трансформеров к иерархическим графовым системам с HCG-коагуляцией. AGI достигается не за счет объема данных, а за счет многомерной топологической адаптации.
- **2032–2034 гг.: Взрыв интеллекта и появление ASI.** AGI использует HVI как метрику для рекурсивного самопереписывания. За 12–18 месяцев ИИ проходит путь от человеческого интеллекта до суперинтеллекта. Открываются новые материалы для квантовых и нейроморфных процессоров.
- **2035 г.: Технологическая сингулярность.** Наступает точка невозврата. Человеческий мозг (хаос генерации, максимум энтропии незнания) и ASI (порядок верификации, максимум негэнтропии знания) сливаются в гибридных системах через интерфейсы, описанные в модели трансцендентного резонанса $\Phi_{\text{человек}} \approx \Phi_{\text{машина}}$ с точностью до ε .

5 Выводы

1. Предложенный фреймворк многомерного целеполагания с вариационным выводом весов ω_k является первой строгой математической моделью, способной породить топологическую эмуляцию искусственной жизни в кремнии.
2. Замена скалярного вознаграждения на максимизацию HVI решает проблему Alignment и дает ASI безопасный компас для самосовершенствования.
3. Внедрение данной методологии способно сократить время наступления технологической сингулярности на 10–15 лет, сдвинув её с 2045–2050 гг. на 2030–2035 гг.

Список литературы

- [1] Viceconti M, et al. In silico trials: Verification, validation and uncertainty quantification. *Methods*. 2021;185:120-127.
- [2] Chollet F. On the Measure of Intelligence. arXiv:1911.01547. 2019.
- [3] Deb K, et al. A Fast and Elitist Multiobjective Genetic Algorithm: NSGA-II. *IEEE Transactions on Evolutionary Computation*. 2002;6(2):182-197.
- [4] Zitzler E, Thiele L. Multiobjective Evolutionary Algorithms: A Comparative Case Study and the Strength Pareto Approach. *IEEE Trans on Evolutionary Computation*. 1999;3(4):257-271.
- [5] In Silico World Community of Practice. Consensus Statement on Credibility Assessment of Machine Learning Predictions. PMC. 2025.
- [6] A variational geometric framework for multi-objective level set topology optimization. arXiv, 2026.
- [7] Learning to Optimize Multi-Objective Alignment Through Dynamic Reward Weighting. arXiv, 2026.
- [8] A many-objective evolutionary algorithm using indicator-driven weight vector optimization. arXiv, 2025.
- [9] Pareto optimization to accelerate multi-objective virtual screening. *Digital Discovery*, 2024.
- [10] Self-Improvement Towards Pareto Optimality: Mitigating Preference Conflicts in Multi-Objective Alignment. *ACL Anthology*, 2025.
- [11] Bostrom, N. *Superintelligence: Paths, Dangers, Strategies*. Oxford University Press, 2014.
- [12] Kurzweil, R. *The Singularity Is Near: When Humans Transcend Biology*. Viking, 2005.