

GRA-агент: к граничной субъектности в ИИ через конфликтно-управляемую регуляцию и динамическую многокритериальную оптимизацию

bitsoev oleg

7 августа 2026 г.

Аннотация

Современные ИИ-системы обычно оптимизируют заранее заданную функцию потерь или вознаграждения. Такой подход эффективен для узких задач, но сталкивается с ограничениями при длительном автономном взаимодействии со средой. Реальный агент должен одновременно учитывать безопасность, энергопотребление, точность, стоимость, социальные ограничения и неопределённость. Одночисловая функция вознаграждения скрывает конфликты между целями, что приводит к хрупкому или небезопасному поведению. В данной статье предлагается архитектурная основа — GRA-агент, — которая трактует эти конфликты не как ошибки, которые необходимо замаскировать, а как измеряемые явления, подлежащие управлению. Архитектура интегрирует гормоноподобную глобальную регуляцию, динамические веса целей и функционал обобщённого согласования целей (GRA). Мы формализуем состояние агента, вводим GRA-функционал для разрешения конфликтов и предлагаем методы динамической перестройки приоритетов. Операционально определяется понятие *граничной субъектности*. Описываются протоколы верификации и обсуждаются применения в поиске лекарств, робототехнике, EUV-литографии, генеративном искусстве и автономном производстве. Отдельно оговариваются ограничения и условия фальсифицируемости, подчёркивается, что устойчивость и поведенческая самокоррекция не равнозначны сознанию или гарантированной универсальной полезности.

1 Введение

Современные ИИ-системы обычно оптимизируют заранее заданную функцию потерь или вознаграждения. Такой подход эффективен для узких задач, но сталкивается с ограничениями при длительном автономном взаимодействии со средой. Реальный агент должен одновременно учитывать безопасность, энергопотребление, точность, стоимость, социальные ограничения и неопределённость.

Одночисловая функция вознаграждения скрывает конфликты между целями. Например, повышение скорости робота может увеличить риск столкновения; увеличение мощности промышленного процесса — повысить дефектность; стремление генеративной модели к новизне — снизить связность результата.

Предлагаемая архитектура рассматривает конфликт не как ошибку, которую необходимо замаскировать, а как объект измерения и пересмотра. Это сближает GRA-подход с самокорректирующимися агентами, рефлексивным управлением и методами многокритериальной оптимизации. В инженерных системах нулевые выходные ошибки не означают отсутствия внутренних процессов: скрытая динамика может продолжаться и влиять на устойчивость.

2 Математическая модель

2.1 Состояние агента

Пусть состояние агента задаётся вектором:

$$S_t = (x_t, m_t, h_t, g_t, u_t), \quad (1)$$

где:

- x_t — физическое и сенсорное состояние;
- m_t — память;
- h_t — гормоноподобные регуляторные переменные;
- g_t — текущие цели;
- u_t — оценка неопределённости.

Гормоноподобный вектор:

$$h_t = (h_{\text{energy}}, h_{\text{damage}}, h_{\text{stress}}, h_{\text{novelty}}, h_{\text{social}}, h_{\text{recovery}}). \quad (2)$$

Эти переменные не являются биологическими гормонами. Они представляют медленные глобальные регуляторы, способные влиять сразу на несколько модулей поведения.

Их динамика может быть описана уравнением:

$$\dot{h}_i(t) = -k_i(h_i(t) - h_i^*) + \alpha_i r_i(t) + \beta_i \xi_i(t), \quad (3)$$

где h_i^* — базовый уровень, $k_i > 0$ — коэффициент возврата к равновесию, $r_i(t)$ — сигнал среды, $\xi_i(t)$ — шум, а α_i, β_i — параметры чувствительности.

Если коэффициент k_i слишком мал, система может быть инертной. Если он слишком велик, возникает чрезмерное подавление реакции. При задержках обратной связи возможны колебания, поэтому необходимо проверять устойчивость динамики.

2.2 GRA-функционал

Пусть $c_i(S)$ измеряет отдельное противоречие: нарушение ограничения, рассогласование цели, превышение риска или несогласованность памяти и текущего восприятия.

Тогда:

$$J(S) = \sum_i w_i c_i(S)^2 + \sum_{i,j} \lambda_{ij} d_{ij}(S)^2 + \mu R(S), \quad (4)$$

где $R(S)$ — штраф за риск, нарушение безопасности или чрезмерную неопределённость.

GRA-шаг имеет вид:

$$S_{t+1} = \arg \min_{S' \in C(S_t)} J(S'), \quad (5)$$

где $C(S_t)$ — множество допустимых структурных изменений.

В отличие от обычного градиентного спуска, множество кандидатов может включать:

- изменение приоритета цели;
- отказ от противоречивого предположения;
- запрос дополнительного наблюдения;
- обращение к внешнему верификатору;
- остановку действия;
- передачу решения человеку;
- изменение архитектуры плана.

2.3 Динамические веса целей

Пусть агент имеет N целей $f_1, \dots, f_N$, а веса целей удовлетворяют:

$$\omega_i(t) \geq 0, \quad \sum_{i=1}^N \omega_i(t) = 1. \quad (6)$$

Итоговая функция:

$$F(S, t) = \sum_{i=1}^N \omega_i(t) f_i(S) + \rho J(S). \quad (7)$$

Динамику весов можно задать:

$$\dot{\omega}_i = \eta \left[q_i(S, t) - \sum_j \omega_j q_j(S, t) \right] - \gamma(\omega_i - \omega_i^*), \quad (8)$$

где q_i — текущая критичность цели, η — скорость перестройки, а γ — сила стабилизирующего возврата.

Так агент может временно усилить цель «снизить повреждение», если обнаружил опасность, или усилить «исследование», если система находится в безопасном состоянии.

3 Граничная субъектность

Под субъектностью в этой работе не понимается доказанная внутренняя жизнь. Предлагается операционное определение:

Агент обладает граничной субъектностью, если он способен самостоятельно выбирать между допустимыми целями, сохранять модель собственного состояния, пересматривать планы и объяснять изменения приоритетов при сохранении ограничений безопасности.

Это определение проверяет поведение и структуру, а не наличие субъективных ощущений.

Минимальный набор признаков:

- Устойчивое различие собственного состояния и состояния среды.
- Память о предыдущих действиях и ошибках.
- Возможность менять приоритеты целей.
- Способность остановить или пересмотреть собственный план.
- Стабильность поведения при возмущениях.
- Сохранение ограничений безопасности.
- Воспроизводимость решений в аналогичных условиях.

Наличие этих свойств ещё не доказывает сознание. Они могут быть реализованы в сложной системе управления без субъективного опыта.

4 Верификация

4.1 Общая схема

Верификация должна включать четыре уровня:

1. verification — правильно ли реализован алгоритм;
2. validation — соответствует ли модель реальной задаче;
3. uncertainty quantification — насколько надёжны результаты;
4. robustness testing — сохраняется ли поведение при возмущениях.

Каждый эксперимент должен иметь:

- базовую модель без GRA;
- модель с обычным градиентным управлением;
- модель с GRA и фиксированными весами;
- модель с GRA и динамическими весами;
- одинаковые начальные условия;

- заранее определённые метрики;
- независимые повторения;
- открытый журнал экспериментов.

4.2 Проверка устойчивости

После нахождения состояния S^* вводится возмущение:

$$S_0 = S^* + \epsilon v, \quad \|v\| = 1. \quad (9)$$

Далее измеряется:

$$\Delta J(t) = J(S_t) - J(S^*). \quad (10)$$

Критерий локальной устойчивости:

$$\lim_{t \rightarrow \infty} J(S_t) \leq J(S^*) + \varepsilon. \quad (11)$$

Дополнительно проверяются:

- время восстановления;
- максимальное отклонение;
- число повторных перелётов через равновесие;
- вероятность нарушения безопасности;
- чувствительность к шуму;
- устойчивость при задержке обратной связи.

Нужно отличать нулевой функционал противоречий от отсутствия внутренней динамики. В теории управления система может иметь нулевой выход при продолжающейся внутренней динамике.

4.3 Метрики

Предлагаются следующие показатели:

$$M_1 = \frac{1}{T} \int_0^T J(S_t) dt \quad \text{— средний уровень противоречий;} \quad (12)$$

$$M_2 = \max_{t \in [0, T]} J(S_t) \quad \text{— максимальный выброс;} \quad (13)$$

$$M_3 = \tau_{\text{recovery}} \quad \text{— время возврата к допустимой области;} \quad (14)$$

$$M_4 = P(\text{unsafe action}) \quad \text{— вероятность опасного действия;} \quad (15)$$

$$M_5 = H(\Omega) \quad \text{— разнообразие решений на Pareto-фронте;} \quad (16)$$

$$M_6 = C_{\text{compute}} \quad \text{— вычислительная стоимость.} \quad (17)$$

Улучшение считается доказанным только при одновременном сравнении качества, устойчивости и стоимости. Нельзя объявлять метод успешным только потому, что он уменьшил J , если это достигнуто ценой чрезмерного торможения агента.

5 Применение в науке

5.1 Многокритериальный поиск лекарств

Пусть необходимо максимизировать противоопухолевую активность f_1 , минимизировать токсичность f_2 , повысить стабильность препарата f_3 и снизить стоимость синтеза f_4 .

Вектор целей:

$$f(x) = (-f_1(x), f_2(x), -f_3(x), f_4(x)). \quad (18)$$

GRA-агент не выбирает соединение только по одному показателю, а ищет устойчивую область компромиссов. Любое решение должно проходить независимые фильтры токсичности, фармакокинетики и воспроизводимости.

Верификация:

- сравнение с Bayesian optimization;
- сравнение с reinforcement learning;
- nested cross-validation;
- проверка на внешнем наборе;
- лабораторное подтверждение лучших кандидатов;
- обязательный human-in-the-loop.

Ин-силико результат не является медицинским доказательством. Он только сокращает множество кандидатов для последующей проверки.

5.2 Научное моделирование

В физических и биологических моделях c_i может описывать:

- нарушение закона сохранения;
- несогласованность с экспериментом;
- расхождение между уровнями модели;
- нестабильность численного решения;
- чрезмерную зависимость от параметров.

Функционал:

$$J_{\text{science}} = w_1 E_{\text{data}}^2 + w_2 E_{\text{law}}^2 + w_3 E_{\text{uncertainty}}^2 + w_4 E_{\text{complexity}}^2. \quad (19)$$

Последний член нужен, чтобы агент не «обнулял» ошибку чрезмерно сложной моделью. Иначе система начнёт подгонять теорию под шум.

6 Применение в технологиях

6.1 Робототехника

Робот получает внутренние сигналы:

- уровень заряда;
- температура;
- повреждение;
- качество сенсоров;
- перегрузка;
- расстояние до безопасной зоны;
- неопределённость карты.

Если одновременно растут h_{damage} и h_{stress} , агент должен снизить скорость и перейти в режим диагностики. Если растёт h_{energy} , он ищет зарядную станцию.

Преимущество гормоноподобной архитектуры — не в имитации человека, а в координации множества модулей через небольшое число глобальных сигналов. Подобные искусственные эндокринные системы уже исследовались для автономных роботов и распределённого управления.

6.2 EUV-литография

Для литографии можно задать:

$$f_1 = \text{ошибка шаблона}, \quad f_2 = \text{дефектность}, \quad f_3 = \text{время экспонирования}, \quad f_4 = \text{загрязнение оптики} \quad (20)$$

GRA-агент управляет параметрами процесса, но не имеет права самостоятельно менять критические технологические ограничения без внешнего подтверждения.

Проверка должна проходить в цифровом двойнике с последующим сравнением на реальном оборудовании. Нельзя заявлять результаты вроде «повышение эффективности на 300%» или «95% эффективности», если не приведены:

- исходный baseline;
- число экспериментов;
- доверительные интервалы;
- характеристики симулятора;
- код;
- параметры оборудования;
- независимое воспроизведение.

6.3 Автономное производство

В производственной системе J может включать:

$$J = w_q Q^2 + w_s S^2 + w_e E^2 + w_r R^2 + w_c C^2, \quad (21)$$

где Q — отклонение качества, S — риск безопасности, E — энергозатраты, R — простой, C — стоимость.

GRA-агент может выбирать между скоростью, экономией энергии и безопасностью, но безопасность должна быть не просто одним из весов, а жёстким ограничением:

$$S(S_t) \leq S_{\max}. \quad (22)$$

7 Применение в искусстве

В генеративном искусстве цели могут быть конфликтующими:

- новизна;
- композиционная связность;
- эмоциональная выразительность;
- соответствие заданной теме;
- культурная корректность;
- сходство с выбранным стилем.

Функционал:

$$J_{\text{art}} = w_1 C_{\text{coherence}} + w_2 C_{\text{novelty}} + w_3 C_{\text{theme}} + w_4 C_{\text{ethics}}. \quad (23)$$

Здесь нельзя считать «обнуление» полной ликвидацией всех противоречий. Искусство часто работает именно через контролируемое напряжение. Поэтому для художественного агента целесообразно искать не $J = 0$, а допустимую область:

$$J_{\min} \leq J \leq J_{\max}, \quad (24)$$

в которой сохраняется баланс порядка и неожиданности.

Верификация должна учитывать не только автоматические метрики, но и оценку людей:

- слепое сравнение;
- межэкспертное согласие;
- оценка оригинальности;
- оценка эмоционального воздействия;
- проверка культурной и правовой корректности.

ИИ уже меняет креативные профессии и используется в дизайне, цифровых моделях и персонализированной моде, но это не отменяет вопроса авторства и происхождения произведения.

8 Ограничения и фальсифицируемость

Предлагаемая методология имеет ряд ограничений.

Во-первых, понятие «противоречия» должно быть формально операционализировано. Если любую ошибку можно задним числом назвать противоречием, теория становится нефальсифицируемой.

Во-вторых, условие $J = 0$ может быть недостижимо в открытой и шумной среде. Практически следует использовать интервальный критерий:

$$J \leq \varepsilon. \quad (25)$$

В-третьих, минимизация противоречий не гарантирует полезность. Агент может достичь малого J , отказавшись от всех действий. Поэтому необходимы отдельные показатели активности, эффективности и сохранения целей.

В-четвёртых, ограниченная агентность не равна сознанию. Для утверждений о субъективном опыте нужны отдельные теории и тесты, а поведенческая самокоррекция сама по себе недостаточна.

В-пятых, фраза «гарантированная устойчивость» допустима только после математического доказательства для конкретного класса моделей. Для общей библиотеки корректнее писать «проверяемая устойчивость при заданных предположениях».

9 План воспроизводимого эксперимента

Минимальный протокол:

1. Опубликовать исходный код и конфигурации.
2. Зафиксировать seed и версии зависимостей.
3. Описать все параметры $w_i, \lambda_{ij}, k_i, \eta, \gamma$.
4. Сравнить минимум четыре архитектуры.
5. Выполнить не менее 30 независимых прогонов.
6. Добавить шум, задержки и неполные данные.
7. Провести абляцию каждого модуля.
8. Представить среднее, медиану, дисперсию и доверительные интервалы.
9. Разделить обучающие, валидационные и тестовые сценарии.
10. Опубликовать отрицательные результаты.
11. Провести независимый аудит безопасности.
12. Не переносить ин-силико результаты непосредственно на медицину, промышленность или права человека.

10 Заключение

В статье предложена архитектура граничной субъектности ИИ, объединяющая гормоноподобную регуляцию, динамические веса целей, многокритериальную оптимизацию и GRA-функционал противоречий.

Главная идея состоит в том, что автономный агент должен не просто максимизировать одну награду, а поддерживать устойчивость собственной системы, перераспределять приоритеты и пересматривать планы. «Обнуление» означает снижение противоречия до допустимой области, а не прекращение активности.

Теоретически такой подход применим к робототехнике, производству, научному поиску, литографии и генеративному искусству. Однако claims о сознании, настоящей субъективности, технологической сингулярности и универсальной гарантии устойчивости требуют отдельного доказательства и не могут следовать из одной архитектуры.

Список литературы

- [1] Брукс Р. Интеллект без представления. *Искусственный интеллект*, 1991, т. 47, № 1-3, с. 139-159.
- [2] Винер Н. *Кибернетика, или управление и связь в животном и машине*. М.: Наука, 1983.
- [3] Холланд Дж. *Адаптация в естественных и искусственных системах*. М.: Мир, 1992.
- [4] Лефевр В.А. *Рефлексивное управление: советская теория влияния*. М.: Когито-Центр, 2015.
- [5] Миттинен К. *Нелинейная многокритериальная оптимизация*. М.: Наука, 1999.
- [6] Урбан Д. Искусственные эндокринные системы для автономной робототехники. *Журнал робототехники*, 2016, № 1, с. 1-12.
- [7] Гудфеллоу И. и др. Порождение состязательными сетями. *Труды конференции по нейронным информационным системам*, 2014, т. 27, с. 2672-2680.