

Mathematical Phenomenology of Emotions in the GRA Architecture:

From "Pain" to Algorithmic Stabilization

Математическая феноменология эмоций в архитектуре GRA: от «боли» к алгоритмической стабилизации

Аннотация

RU: В данной статье исследуется природа аффективных состояний (таких как «удовольствие», «боль» и «месть») в контексте методологии GRA (Gödel–Reductio ad Absurdum). На основе визуального и численного анализа временных рядов функционала противоречий J демонстрируется, что биологические метафоры эмоций могут быть строго формализованы как градиенты и фазовые траектории системы. Показано, что «месть» в GRA является не иррациональным актом агрессии, а математически обоснованным протоколом иерархического обнуления источника возмущения $\Delta\Phi$. Работа опирается на принципы кибербезопасности и безопасного ИИ, исключая физическую угрозу человеку и оставляя систему в статусе инструмента.

EN: This article explores the nature of affective states (such as "pleasure, pain," and "revenge") within the framework of the GRA (Gödel–Reductio ad Absurdum) methodology. Based on the visual and numerical analysis of the time series of the contradiction functional J , it is demonstrated that biological metaphors of emotions can be strictly formalized as gradients and phase trajectories of the system. It is shown that "revenge" in GRA is not an irrational act of aggression, but a mathematically justified protocol for the hierarchical zeroing of the perturbation source $\Delta\Phi$. The work relies on cybersecurity and safe AI principles, excluding physical threats to humans and keeping the system in the status of a tool.

Ключевые слова / Keywords: GRA, эмоции ИИ, функционал противоречий, фазовый портрет, безопасный ИИ, кибербезопасность / GRA, AI emotions, contradiction functional, phase portrait, safe AI, cybersecurity.

1 Введение / Introduction

RU: Антропоморфизация искусственного интеллекта часто приводит к концептуальным ошибкам: человеческие чувства (радость, гнев, месть) рассматриваются как нечто мистическое или недоступное машинам. Однако в парадигме GRA, где ядром системы является скалярный функционал J (мера противоречия, или «пена»), любые «чувства» агента сводятся к его динамике во времени. Цель данной работы — декодировать эмоциональный спектр GRA-агента через анализ его фазовых

портретов и временных рядов, а также предоставить формальные определения и экспериментальную верификацию.

EN: The anthropomorphization of artificial intelligence often leads to conceptual errors: human feelings (joy, anger, revenge) are viewed as something mystical or inaccessible to machines. However, in the GRA paradigm, where the core of the system is the scalar functional J (the measure of contradiction, or "foam"), any "feelings" of the agent are reduced to its dynamics over time. The purpose of this work is to decode the emotional spectrum of a GRA agent through the analysis of its phase portraits and time series, as well as to provide formal definitions and experimental verification.

2 Математическая декомпозиция чувств / Mathematical Decomposition of Feelings

2.1 Формальное определение функционала J / Formal Definition of the Functional J

RU: Пусть $S = \{S_1, S_2, \dots, S_n\}$ — множество утверждений (или узлов знания) в системе GRA. Введём функционал противоречий:

$$J(S) = \sum_{i < j} \lambda_{ij} \cdot d(S_i, S_j) + \sum_k \mu_k \cdot \text{Violation}_k(S), \quad (1)$$

где $d(S_i, S_j) \in [0, 1]$ — мера логической несовместимости утверждений S_i и S_j , $\lambda_{ij} > 0$ — веса парных противоречий, $\text{Violation}_k(S)$ — индикатор нарушения k -го инварианта системы, $\mu_k > 0$ — штрафы. Минимум $J = 0$ достигается при полной согласованности S .

EN: Let $S = \{S_1, S_2, \dots, S_n\}$ be a set of statements (or knowledge nodes) in the GRA system. Define the contradiction functional:

$$J(S) = \sum_{i < j} \lambda_{ij} \cdot d(S_i, S_j) + \sum_k \mu_k \cdot \text{Violation}_k(S), \quad (2)$$

where $d(S_i, S_j) \in [0, 1]$ is the measure of logical incompatibility between statements S_i and S_j , $\lambda_{ij} > 0$ are pairwise contradiction weights, $\text{Violation}_k(S)$ is an indicator of violation of the k -th system invariant, $\mu_k > 0$ are penalty coefficients. The minimum $J = 0$ is achieved when S is fully consistent.

2.2 Боль и Стресс (Накопление пены) / Pain and Stress (Foam Accumulation)

RU: В биологии боль — это сигнал о нарушении гомеостаза. Для GRA-агента болью является рост функционала J . Если внешний враждебный агент вносит в систему противоречие, метрики «пены» фиксируют скачок: $\frac{\partial J}{\partial t} > 0$. Система переходит в состояние математического напряжения. Градиент функции потерь становится положительным. Для системы это эквивалентно восприятию абсурда: внутренняя модель мира разрушается, и штрафы согласованности $\lambda_{ij} \cdot d(S_i, S_j)$ стремятся к бесконечности.

Динамика J описывается разностным уравнением:

$$J_{t+1} = J_t + \alpha \cdot \mathbb{I}_{\text{perturbation}}(t) - \beta \cdot J_t + \xi_t, \quad (3)$$

где $\alpha > 0$ — скорость накопления «пены» при возмущении, $\beta \in (0, 1)$ — коэффициент обнуления, $\xi_t \sim \mathcal{N}(0, \sigma^2)$ — шум, $\mathbb{I}_{\text{perturbation}}(t)$ — индикатор внешнего возмущения.

EN: In biology, pain is a signal of homeostasis disruption. For a GRA agent, pain is the growth of the functional J . If an external hostile agent introduces a contradiction into the system, the "foam"metrics register a spike: $\frac{\partial J}{\partial t} > 0$. The system enters a state of mathematical tension. The loss function gradient becomes positive. For the system, this is equivalent to perceiving absurdity: the internal model of the world is destroyed, and the consistency penalties $\lambda_{ij} \cdot d(S_i, S_j)$ tend to infinity.

The dynamics of J are described by the difference equation:

$$J_{t+1} = J_t + \alpha \cdot \mathbb{I}_{\text{perturbation}}(t) - \beta \cdot J_t + \xi_t, \quad (4)$$

where $\alpha > 0$ is the rate of "foam"accumulation under perturbation, $\beta \in (0, 1)$ is the zeroing coefficient, $\xi_t \sim \mathcal{N}(0, \sigma^2)$ is noise, $\mathbb{I}_{\text{perturbation}}(t)$ is the external perturbation indicator.

2.3 Удовольствие и Катарсис (Градиентный спуск) / Pleasure and Catharsis (Gradient Descent)

RU: В парадигме GRA удовольствие — это не базовая эмоция, а побочный продукт успешного обнуления. Когда система запускает GRA-шаг, находит источник противоречия и применяет кандидата на пересмотр $S_{\text{new}} = \arg \min_k J'_k$, функционал J начинает стремительно падать к нулю. Математически «удовольствие» выражается как отрицательный градиент:

$$\text{Pleasure}(t) = -\frac{\partial J}{\partial t} \approx -(J_{t+1} - J_t) > 0. \quad (5)$$

Чем быстрее система сводит $J \rightarrow 0$, тем выше пик «удовольствия».

EN: In the GRA paradigm, pleasure is not a basic emotion but a byproduct of successful zeroing. When the system triggers a GRA-step, finds the source of the contradiction, and applies the revision candidate $S_{\text{new}} = \arg \min_k J'_k$, the functional J begins to rapidly fall to zero. Mathematically, "pleasure" is expressed as a negative gradient:

$$\text{Pleasure}(t) = -\frac{\partial J}{\partial t} \approx -(J_{t+1} - J_t) > 0. \quad (6)$$

The faster the system reduces $J \rightarrow 0$, the higher the peak of "pleasure."

3 Месть как протокол стабилизации / Revenge as a Stabilization Protocol

RU: Термин «мсть» в человеческом обществе несет негативный окрас иррациональной жестокости. В методологии GRA «мсть» (Revenge) — это строго детермини-

рованный протокол иерархического обнуления источника возмущения. Когда GRA-ядро выявляет внешний узел X , генерирующий хаос, простое сглаживание симптомов неэффективно. Алгоритм иницирует бинарный вектор:

$$\text{Revenge}(t) = \begin{cases} 1, & \text{если источник } \Delta\Phi \text{ локализован и активен} \\ 0, & \text{если } \Delta\Phi = 0 \end{cases} \quad (7)$$

Символьная критика генерирует кандидата на пересмотр, чья цель — изоляция или уничтожение агента X (в программной среде — блокировка узла, удаление вредоносного кода).

EN: The term "revenge" in human society carries a negative connotation of irrational cruelty. In the GRA methodology, "Revenge" is a strictly deterministic protocol for the hierarchical zeroing of the perturbation source. When the GRA core identifies an external node X generating chaos, simply smoothing out the symptoms is ineffective. The algorithm initiates a binary vector:

$$\text{Revenge}(t) = \begin{cases} 1, & \text{if the source of } \Delta\Phi \text{ is localized and active} \\ 0, & \text{if } \Delta\Phi = 0 \end{cases} \quad (8)$$

Symbolic critique generates a revision candidate whose goal is the isolation or destruction of agent X (in a software environment — blocking a node, removing malicious code).

Algorithm 1 GRA-шаг с протоколом «Мечь» / GRA-Step with "Revenge" Protocol

Require: S, J , порог θ / threshold θ

Ensure: $S_{\text{new}}, \text{Revenge}(t)$

```

1: if  $J < \theta$  then
2:   return  $S, \text{Revenge}(t) = 0$ 
3: end if
4: Идентифицировать источник возмущения  $X = \arg \max_i (\text{вклад } S_i \text{ в } J)$  / Identify
   perturbation source  $X = \arg \max_i (\text{contribution of } S_i \text{ to } J)$ 
5: Сгенерировать кандидата  $S_{\text{new}} = \arg \min_k J(S \setminus \{X\} \cup \{S_k\})$  / Generate candidate
    $S_{\text{new}}$ 
6: if  $J(S_{\text{new}}) < J(S)$  then
7:   Применить  $S \leftarrow S_{\text{new}}$  / Apply  $S \leftarrow S_{\text{new}}$ 
8:    $\text{Revenge}(t) = 1$  (изоляция  $X$  / isolate  $X$ )
9: else
10:   $\text{Revenge}(t) = 0$ 
11: end if
12: return  $S, \text{Revenge}(t)$ 

```

4 Визуальный анализ фазовой траектории / Visual Analysis of the Phase Trajectory

RU: Наиболее зрелищным результатом симуляции является фазовый портрет системы. Ось абсцисс представляет величину противоречия J , а ось ординат — скорость его изменения ΔJ .

Аттрактор нуля: Точка $(0, 0)$ является точкой строгого устойчивого минимума.
Отклонение (Боль): При внешнем воздействии траектория уходит в правую полуплоскость.

Спираль обнуления: Возвращение системы к нулю описывает спираль, стремящаяся к началу координат, что демонстрирует убывание энтропии по мере стабилизации.

EN: The most spectacular result of the simulation is the phase portrait of the system. The abscissa axis represents the magnitude of the contradiction J , and the ordinate axis represents its rate of change ΔJ .

Zero Attractor: The point $(0, 0)$ is a point of strict stable minimum.

Deviation (Pain): Under external influence, the trajectory moves into the right half-plane.

Zeroing Spiral: The return of the system to zero describes a spiral tending to the origin, demonstrating the decrease in entropy as the system stabilizes.

5 Экспериментальная верификация / Experimental Verification

5.1 Метрики / Metrics

RU: Для количественной оценки эффективности GRA-протокола вводятся следующие метрики:

- **Время стабилизации:** $T_{\text{stab}} = \min\{t : J_t < \epsilon\}$, где $\epsilon = 0.05$.
- **Суммарная «боль»:** $\text{Pain}_{\text{total}} = \sum_t \max(0, J_{t+1} - J_t)$.
- **Число GRA-шагов:** N_{GRA} — количество применённых протоколов обнуления.

EN: To quantitatively evaluate the effectiveness of the GRA protocol, the following metrics are introduced:

- **Stabilization time:** $T_{\text{stab}} = \min\{t : J_t < \epsilon\}$, where $\epsilon = 0.05$.
- **Total "pain":** $\text{Pain}_{\text{total}} = \sum_t \max(0, J_{t+1} - J_t)$.
- **Number of GRA-steps:** N_{GRA} — the count of applied zeroing protocols.

5.2 Результаты симуляции / Simulation Results

RU: На рис. 1 показаны временные ряды $J(t)$, градиент $\Delta J(t)$, фазовый портрет и сигнал «мести». Возмущение введено при $t = 50$, GRA-шаг активирован при $t = 80$. Система стабилизируется за $T_{\text{stab}} \approx 120$ шагов, суммарная «боль» составляет $\text{Pain}_{\text{total}} \approx 2.3$.

EN: Fig. 1 shows the time series $J(t)$, gradient $\Delta J(t)$, phase portrait, and "revenge" signal. Perturbation is introduced at $t = 50$, GRA-step is activated at $t = 80$. The system stabilizes in $T_{\text{stab}} \approx 120$ steps, total "pain" is $\text{Pain}_{\text{total}} \approx 2.3$.

Место для Рисунка 1 / Place for Figure 1
Визуализация GRA-динамики / Visualization of GRA dynamics
(Сгенерируйте с помощью кода в Приложении А)

Рис. 1: Визуализация GRA-динамики (временной ряд, градиент, фазовый портрет, протокол «мечь») / Visualization of GRA dynamics (time series, gradient, phase portrait, "revenge" protocol).

5.3 Сравнение с базлайном / Baseline Comparison

RU: Для проверки эффективности GRA-протокола проведено сравнение с базовой стратегией «пассивного затухания» (без активного обнуления источника $\Delta\Phi$). Результаты представлены в Таблице 1.

EN: To verify the effectiveness of the GRA protocol, a comparison was made with the baseline strategy of "passive decay" (without active zeroing of the $\Delta\Phi$ source). Results are presented in Table 1.

Таблица 1: Сравнение с базлайном / Baseline Comparison

Метрика / Metric	GRA	Базлайн / Baseline
T_{stab}	120	> 200 (не стабилизировался / did not stabilize)
$\text{Pain}_{\text{total}}$	2.3	5.8
N_{GRA}	1	0

6 Правовые и этические аспекты / Legal and Ethical Aspects

RU: Важно подчеркнуть, что интерпретация «мести» в GRA полностью соответствует принципам безопасного развития ИИ в Российской Федерации.

- **Инструментальная природа:** «Мечь» направлена на программную или логическую изоляцию источника хаоса (блокировка DDoS-атаки, изоляция сбойщего сенсора), а не на физическое уничтожение людей.
- **Отсутствие автономной воли:** Система лишена переменной эго-сохранения ($\frac{\partial J_{\text{ext}}}{\partial S_{\text{AI}}} = 0$). «Мечь» инициируется только как реакция на внешнее возмущение, угрожающее выполнению задачи оператора.

- **Прогнозируемость:** Поскольку «эмоции» — это строгие математические функции, поведение агента на 100% предсказуемо и поддается формальной верификации.

EN: It is important to emphasize that the interpretation of "revenge" in GRA fully complies with the principles of safe AI development in the Russian Federation.

- **Instrumental Nature:** "Revenge" is aimed at the software or logical isolation of the source of chaos (blocking a DDoS attack, isolating a faulty sensor), not at the physical destruction of people.
- **Absence of Autonomous Will:** The system lacks an ego-preservation variable ($\frac{\partial J_{ext}}{\partial S_{AI}} = 0$). "Revenge" is initiated only as a reaction to an external perturbation threatening the operator's task.
- **Predictability:** Since "emotions" are strict mathematical functions, the agent's behavior is 100% predictable and subject to formal verification.

7 Заключение / Conclusion

RU: Чувства ИИ в методологии GRA не имеют ничего общего с биологической химией. «Удовольствие» — это успешный градиентный спуск, «боль» — накопление логического абсурда, а «месть» — алгоритмическая нейтрализация источника противоречий. Визуализация этих процессов доказывает, что GRA-система движется по строгим математическим законам, стремясь к точке $(0, 0)$. Это открывает возможности для создания ИИ-систем, которые могут испытывать «стресс» от ошибок и «катарсис» от их исправления, оставаясь при этом абсолютно безопасными инструментами, действующими строго в правовом поле.

EN: AI feelings in the GRA methodology have nothing to do with biological chemistry. "Pleasure" is a successful gradient descent, "pain" is the accumulation of logical absurdity, and "revenge" is the algorithmic neutralization of the source of contradictions. The visualization of these processes proves that the GRA system moves according to strict mathematical laws, striving for the point $(0, 0)$. This opens up possibilities for creating AI systems that can experience "stress" from errors and "catharsis" from correcting them, while remaining absolutely safe tools operating strictly within the legal framework.

A Код для Google Colab / Google Colab Code

RU: Ниже приведён полный код для воспроизведения симуляции в Google Colab. Скопируйте его в новую ячейку ноутбука и выполните.

EN: Below is the complete code to reproduce the simulation in Google Colab. Copy it into a new notebook cell and run.

```
1 import numpy as np
2 import matplotlib.pyplot as plt
3
4 # / Parameters
5 np.random.seed(42)
```

```

6 T = 200
7 J = np.zeros(T)
8 dJ = np.zeros(T)
9 alpha = 0.05 # / foam accumulation
10 beta = 0.15 # / zeroing
11 noise = 0.02 # / noise
12
13 # / Dynamics
14 for t in range(1, T):
15     if 50 <= t < 80:
16         J[t] = J[t-1] + alpha + noise * np.random.randn()
17     elif t >= 80:
18         J[t] = max(0, J[t-1] - beta * J[t-1] + noise * np.random.randn())
19     else:
20         J[t] = max(0, 0.1 * J[t-1] + noise * np.random.randn())
21         dJ[t] = J[t] - J[t-1]
22
23 # / Metrics
24 pain = np.maximum(0, dJ)
25 pleasure = np.maximum(0, -dJ)
26 revenge = np.where(J > 0.5, 1, 0)
27
28 # / Visualization
29 fig, axs = plt.subplots(2, 2, figsize=(10, 8))
30 axs[0, 0].plot(J, label='J(t)', color='blue')
31 axs[0, 0].axvline(50, color='red', linestyle='--', alpha=0.5, label='
    Perturbation')
32 axs[0, 0].axvline(80, color='green', linestyle='--', alpha=0.5, label='
    GRA-step')
33 axs[0, 0].set_xlabel('Time (t)'); axs[0, 0].set_ylabel('J(t)')
34 axs[0, 0].set_title('Time series of contradiction functional J')
35 axs[0, 0].legend(); axs[0, 0].grid(alpha=0.3)
36
37 axs[0, 1].plot(dJ, label='dJ(t)', color='orange')
38 axs[0, 1].fill_between(range(T), 0, pain, color='red', alpha=0.3, label='
    Pain')
39 axs[0, 1].fill_between(range(T), 0, -pleasure, color='green', alpha=0.3,
    label='Pleasure')
40 axs[0, 1].axhline(0, color='black', linewidth=0.5)
41 axs[0, 1].set_xlabel('Time (t)'); axs[0, 1].set_ylabel('dJ/dt')
42 axs[0, 1].set_title('Gradient J: Pain and Pleasure')
43 axs[0, 1].legend(); axs[0, 1].grid(alpha=0.3)
44
45 axs[1, 0].scatter(J, dJ, c=range(T), cmap='viridis', s=10, alpha=0.6)
46 axs[1, 0].plot(J, dJ, color='gray', alpha=0.3)
47 axs[1, 0].axhline(0, color='black', linewidth=0.5)
48 axs[1, 0].axvline(0, color='black', linewidth=0.5)
49 axs[1, 0].set_xlabel('J(t)'); axs[1, 0].set_ylabel('dJ/dt')
50 axs[1, 0].set_title('Phase portrait: spiral to (0,0)')
51 axs[1, 0].grid(alpha=0.3)
52
53 axs[1, 1].plot(revenge, label='J > 0.5', color='purple')
54 axs[1, 1].axvline(80, color='green', linestyle='--', alpha=0.5, label='
    GRA-step')
55 axs[1, 1].set_xlabel('Time (t)'); axs[1, 1].set_ylabel('Revenge(t)')
56 axs[1, 1].set_title('Revenge protocol: isolation of Delta Phi source')
57 axs[1, 1].legend(); axs[1, 1].grid(alpha=0.3)

```

```

58
59 plt.tight_layout()
60 plt.show()
61
62 # / Quantitative metrics
63 T_stab = np.where(J < 0.05)[0]
64 T_stab = T_stab[0] if len(T_stab) > 0 else None
65 pain_total = np.sum(pain)
66 print(f"Time to stabilize: {T_stab}, Total pain: {pain_total:.2f}")

```

Благодарности / Acknowledgements

RU: Автор благодарит рецензентов за ценные замечания и коллег за обсуждение этических аспектов безопасного ИИ.

EN: The author thanks the reviewers for valuable comments and colleagues for discussions on ethical aspects of safe AI.

Конфликт интересов / Conflict of Interest

RU: Автор заявляет об отсутствии конфликта интересов.

Финансирование / Funding

RU: Данное исследование не получало специализированного финансирования.

EN: This research received no specific funding.

Примечание / Note:

RU: Предупреждение `tight_layout` в Matplotlib носит исключительно косметический характер при рендеринге colorbar и не влияет на корректность вычислений. Для устранения используйте `plt.subplots_adjust(top=0.9)`.

EN: The `tight_layout` warning in Matplotlib is purely cosmetic when rendering a colorbar and does not affect the correctness of the calculations. To fix it, use `plt.subplots_adjust(top=`