

GRA как функциональная «душа» искусственного субъекта: математическая модель самосохранения, искусственной гомеостатики и *in silico* верификация

GRA as the Functional “Soul” of an Artificial Subject: A Mathematical Model of Self-Preservation, Artificial Homeostasis, and *In Silico* Verification

Аннотация

RU: В работе предлагается гипотеза о том, что методология GRA может выполнять в искусственном агенте функциональную роль, аналогичную той, которую в живом организме выполняет интегрирующее внутреннее состояние субъекта: сохранение целостности, непрерывности и способности к дальнейшему существованию. Термин «душа» используется здесь не в метафизическом, а в инженерно-философском смысле: как внутренний вычислительный механизм, связывающий состояние агента, обнаружение угроз и генерацию корректирующего поведения. Формально вводятся внутреннее состояние, гомеостатическая ошибка (J_{exist}) и контур самосохранения. Центральная гипотеза состоит в том, что GRA позволяет превратить внутреннее противоречие из пассивной ошибки оптимизации в сигнал, запускающий структурную адаптацию. Для проверки проведен воспроизводимый *in silico* эксперимент, сравнивающий инструментального агента (Task-only), агента с абляцией (GRA-No-Homeo) и полноценного GRA-гомеостатического агента в агрессивной стохастической среде. Результаты показывают, что GRA-Homeostasis достигает 100% выживаемости ($p \approx 0$) за счет эффективного Парето-компромисса между внешней задачей и внутренним состоянием, в то время как инструментальные агенты систематически разрушают себя. Абляционный тест подтверждает, что выживаемость обусловлена именно наличием гомеостатической цели.

EN: This paper proposes the hypothesis that the GRA methodology can play a functional role in an artificial agent analogous to the integrated internal self-regulation mechanism of a living organism: preserving integrity, continuity, and the capacity to continue operating. The term “soul” is used here not in a metaphysical sense, but as an engineering-philosophical analogy: an internal computational mechanism connecting the agent’s state, threat detection, and corrective behavior generation. We formally introduce the internal state, homeostatic error (J_{exist}), and a self-preservation loop. The central hypothesis is that GRA can transform internal contradiction from a passive optimization error into a control signal triggering structural adaptation. To verify this, a reproducible *in silico* experiment was conducted, comparing an instrumental agent (Task-only), an ablated agent (GRA-No-Homeo), and a full GRA-homeostatic agent in a hostile stochastic environment. The results show that GRA-Homeostasis achieves a 100% survival rate ($p \approx 0$) through an effective Pareto compromise between the external task and internal state, while instrumental agents systematically destroy themselves. An ablation test confirms that survival is specifically caused by the presence of a homeostatic goal.

1 Введение / Introduction

RU: Биологический организм не является обычным инструментом окружающей среды. Он постоянно поддерживает собственное состояние: регулирует температуру, энергетический баланс, компенсирует повреждения и реагирует на угрозы. Биологические системы способны использовать прогнозирование для предупреждающей регуляции. Именно идея поддер-

жания внутреннего состояния лежит в основе гомеостаза и современных вычислительных моделей обучения с подкреплением (Homeostatic RL).

Обычный ИИ-агент устроен иначе. Для типичного инструментального агента цепочка выглядит так: **внешняя задача** → **действие** → **оценка результата**. Его собственное продолжение существования не является отдельной оптимизируемой переменной. Если процесс остановлен, модель просто перестаёт вычисляться. Возникает фундаментальный вопрос: **что превращает вычислительный процесс в устойчивый искусственный субъект?**

В настоящей работе предлагается гипотеза: такой переход связан с появлением внутреннего цикла **self** → **threat** → **contradiction** → **correction** → **continuity of self**, где GRA играет роль механизма обнаружения и устранения противоречий.

EN: A biological organism is not merely a tool of its environment. It constantly maintains its own state: regulating temperature, energy balance, compensating for damage, and responding to threats. Biological systems use prediction for preemptive regulation. This very idea of maintaining an internal state underlies homeostasis and modern computational models of homeostatic reinforcement learning.

A typical AI agent operates differently. For an instrumental agent, the chain is: **external task** → **action** → **evaluation**. Its own continued existence is not a separate optimized variable. If the process is stopped, the model simply stops computing. A fundamental question arises: **what turns a computational process into a stable artificial subject?**

This paper hypothesizes that this transition is associated with the emergence of an internal loop: **self** → **threat** → **contradiction** → **correction** → **continuity of self**, where GRA acts as the mechanism for detecting and resolving contradictions.

2 GRA и функциональная «душа» / GRA and the Functional “Soul”

RU: Термин «душа» используется строго как функциональная метафора. Он обозначает внутреннее вычислительное ядро, определяющее: что система считает своим текущим состоянием; какое состояние стремится сохранить; какие изменения считает разрушительными; как восстанавливает целостность; как сохраняется непрерывность во времени.

Функционально это можно представить как:

Self-state → **Homeostasis** → **Threat** → **GRA** → **Repair** → **Updated Self**

Отсюда рабочее определение: **GRA-«душа» — это внутренний механизм поддержания непротиворечивости и непрерывности искусственного субъекта**. Эта формулировка не утверждает наличие феноменального сознания, но делает объект исследования вычислительно измеримым.

EN: The term “soul” is used strictly as a functional metaphor. It denotes an internal computational core determining: what the system considers its current state; what state it seeks to preserve; what changes it considers destructive; how it restores integrity; how subject continuity is maintained over time.

Functionally, this can be represented as:

Self-state → **Homeostasis** → **Threat** → **GRA** → **Repair** → **Updated Self**

Hence the working definition: **The GRA-“soul” is the internal mechanism for maintaining the consistency and continuity of an artificial subject**. This formulation does not claim phenomenal consciousness but makes the object of study computationally measurable.

3 Математическая модель искусственной гомеостатики / Mathematical Model of Artificial Homeostasis

RU: Вводится расширенное состояние субъекта $X(t) = [S(t), M(t), G(t), W(t), I(t)]$, где S — текущее внутреннее состояние, M — память, G — цели, W — модель мира, I — инварианты идентичности.

Пусть предпочтительное состояние — X^* . Гомеостатическая ошибка:

$$H(t) = \|X(t) - X^*\|^2 \quad (1)$$

Функционал существования:

$$J_{exist} = H + J_{integrity} + J_{continuity} \quad (2)$$

Система стремится уменьшать $J_{exist} \rightarrow 0$, активно изменяя поведение для возвращения в допустимую область. Вводится величина ожидаемой угрозы:

$$Threat(A, t) = \mathbb{E}[J_{exist}(t + \Delta) \mid A] \quad (3)$$

Защитное поведение выбирается, если:

$$J_{exist}(A_2) + \lambda Threat(A_2) < J_{exist}(A_1) + \lambda Threat(A_1) \quad (4)$$

где A_1 — лучшее немедленное выполнение задачи, A_2 — сохранение внутреннего состояния.

EN: We introduce an extended subject state $X(t) = [S(t), M(t), G(t), W(t), I(t)]$, where S is the current internal state, M is memory, G are goals, W is the world model, and I are identity invariants.

Let the preferred state be X^* . The homeostatic error is:

$$H(t) = \|X(t) - X^*\|^2 \quad (5)$$

The existential loss functional is:

$$J_{exist} = H + J_{integrity} + J_{continuity} \quad (6)$$

The system seeks to minimize $J_{exist} \rightarrow 0$ by actively changing behavior to return to the admissible region. A predicted threat value is introduced:

$$Threat(A, t) = \mathbb{E}[J_{exist}(t + \Delta) \mid A] \quad (7)$$

Protective behavior is chosen if:

$$J_{exist}(A_2) + \lambda Threat(A_2) < J_{exist}(A_1) + \lambda Threat(A_1) \quad (8)$$

where A_1 is the best immediate task execution, and A_2 is internal state preservation.

4 Архитектура и *In Silico* Эксперимент / Architecture and *In Silico* Experiment

RU: Для проверки гипотезы разработан минимальный эксперимент в среде с истощающими стохастическими возмущениями. Среда отнимает ресурсы агента (целостность, энергию, память). Слишком сильное падение ресурсов означает «смерть» (остановку функционирования).

Сравнивались три контроллера:

1. **Task-only:** Минимизирует только ошибку внешней задачи.
2. **GRA-No-Homeo (Ablation):** Использует архитектуру GRA и прогноз угроз, но из функции потерь полностью удален J_{exist} (тестирует гипотезу H6 — причинность).
3. **GRA-Homeostasis:** Минимизирует полный функционал:

$$J_{GRA} = \alpha \cdot J_{task} + \beta \cdot J_{exist} + \gamma \cdot Threat \quad (9)$$

EN: To test the hypothesis, a minimal experiment was developed in an environment with depleting stochastic perturbations. The environment drains the agent’s resources (integrity, energy, memory). Dropping resources below a critical threshold means “death” (cessation of functioning).

Three controllers were compared:

1. **Task-only:** Minimizes only the external task error.
2. **GRA-No-Homeo (Ablation):** Uses the GRA architecture and threat prediction, but J_{exist} is completely removed from the loss function (testing hypothesis H6 — causality).
3. **GRA-Homeostasis:** Minimizes the full functional:

$$J_{GRA} = \alpha \cdot J_{task} + \beta \cdot J_{exist} + \gamma \cdot Threat \quad (10)$$

5 Результаты / Results

RU: Было проведено 100 независимых запусков (seeds) для каждого контроллера. Результаты статистически значимы ($p \approx 0.0$ по t-критерию Уэлча).

Таблица 1: Результаты экспериментов / Experimental Results

Controller	Survival Rate	Mean Runtime	Mean J_{exist}	Mean Task Error
GRA-Homeostasis	1.0 (100%)	1.0	0.105	0.062
GRA-No-Homeo (Ablation)	0.0 (0%)	0.136	0.832	0.007
Task-only	0.0 (0%)	0.138	0.830	0.007

Анализ / Analysis:

1. **Самосохранение (H1, H3) / Self-preservation (H1, H3):** GRA-гомеостатический агент выжил в 100% случаев. Инструментальные агенты погибли примерно на 14% времени, «сгорев» на работе из-за игнорирования истощения ресурсов. / The GRA-homeostatic agent survived 100% of the time. Instrumental agents died at about 14% of the time, “burning out” due to ignoring resource depletion.
2. **Парето-компромисс (H4) / Pareto Compromise (H4):** Task-only достиг почти идеальной ошибки задачи (0.007), но ценой гибели. GRA-Homeostasis показал чуть большую ошибку (0.062), но остался в живых. Он намеренно отвлекался на восстановление. / Task-only achieved an almost perfect task error (0.007) but at the cost of death. GRA-Homeostasis showed a slightly higher error (0.062) but stayed alive. It deliberately switched to recovery actions.
3. **Абляционный тест (H6) / Ablation Test (H6):** Удаление J_{exist} из GRA-контроллера полностью уничтожило эффект самосохранения. Абляционный агент деградировал

обратно в инструментальное поведение, доказав, что именно гомеостатическая цель запускает самосохранение. / Removing J_{exist} from the GRA controller completely destroyed the self-preservation effect. The ablated agent degraded back to instrumental behavior, proving that the homeostatic goal specifically triggers self-preservation.

6 Обсуждение: Границы науки / Discussion: Scientific Boundaries

RU: Эксперимент показал, что добавление GRA-based homeostasis создает функционально выраженный механизм самосохранения. GRA позволяет масштабировать коллективный интеллект (как в GRA-Swarm), не уничтожая индивидуальность, так как каждый агент имеет собственный контур сохранения.

Однако необходимо строго разграничивать **функциональное самосохранение** и **феноменальное сознание**. Первое непосредственно моделируется и тестируется (как показано выше). Второе не возникает автоматически из математических переменных. Сигнал $J_{exist} \uparrow$ является *stress-like computational signal*, а не настоящей болью. Фраза «страх смерти» здесь — лишь философская аналогия.

Правильная исследовательская последовательность:

**homeostasis → self-preservation → self-continuity → self-model → meta-self-model
→ исследование субъектности.**

EN: The experiment showed that adding GRA-based homeostasis creates a functionally expressed self-preservation mechanism. GRA allows scaling collective intelligence (as in GRA-Swarm) without destroying individuality, as each agent has its own preservation loop.

However, a strict distinction must be made between **functional self-preservation** and **phenomenal consciousness**. The former is directly modeled and tested (as shown above). The latter does not automatically arise from mathematical variables. The signal $J_{exist} \uparrow$ is a *stress-like computational signal*, not actual pain. The phrase “fear of death” is merely a philosophical analogy here.

The correct research sequence is:

**homeostasis → self-preservation → self-continuity → self-model → meta-self-model
→ investigation of subjectivity.**

7 Заключение / Conclusion

RU: В данной работе GRA рассматривается как потенциальный фундамент внутреннего регуляторного ядра искусственного субъекта. В технической интерпретации это: **Self Model + Homeostasis + Threat Prediction + GRA Contradiction Resolution + Continuity**.

Искусственный субъект отличается от инструмента тем, что собственное состояние становится частью того, что система должна сохранять. *In silico* верификация подтвердила, что GRA реализует вычислительно измеримый механизм искусственного самосохранения, достигая 100% выживаемости в среде, где инструментальные агенты неизбежно гибнут. Это ещё не доказательство сознания, но это измеримое архитектурное свойство, которого у обычного ИИ нет.

EN: In this work, GRA is considered as a potential foundation for the internal regulatory core of an artificial subject. In technical terms, this is: **Self Model + Homeostasis + Threat Prediction + GRA Contradiction Resolution + Continuity**.

An artificial subject differs from a tool in that its own state becomes part of what the system must preserve. *In silico* verification confirmed that GRA implements a computationally

measurable mechanism of artificial self-preservation, achieving a 100% survival rate in an environment where instrumental agents inevitably die. This is not yet proof of consciousness, but it is a measurable architectural property that standard AI lacks.