

Методология GRA как функциональная «душа» роя искусственных субъектов: Математическая модель самосохранения, коллективной гомеостатики и In Silico верификация

GRA Methodology as the Functional “Soul” of a Swarm of Artificial
Subjects: A Mathematical Model of Self-Preservation, Collective
Homeostatics, and In Silico Verification

September 15, 2026

Abstract

RU: В данной работе предлагается концепция функциональной «души» искусственного агента на основе методологии GRA (Gödel–Reductio ad Absurdum), реализованной в библиотеке GRA-Core-new. Термин «душа» рассматривается строго в инженерно-философском смысле как внутренний вычислительный контур самосохранения, обнаружения угроз и устранения противоречий. Вводится математическая модель искусственной гомеостатики, основанная на функционале существования J_{exist} , и расширяется до уровня роя субъектных агентов. Проведена воспроизводимая *in silico* верификация, демонстрирующая 100% выживаемость GRA-агентов в агрессивной среде по сравнению с инструментальными агентами. Обсуждаются качественно новые эмерджентные свойства роя одушевлённых агентов: коллективная рефлексия, искусственная культура и самокоррекция «идеологии».

EN: This paper proposes a concept of the functional “soul” of an artificial agent based on the GRA (Gödel–Reductio ad Absurdum) methodology, implemented in the GRA-Core-new library. The term “soul” is used strictly in an engineering-philosophical sense as an internal computational loop for self-preservation, threat detection, and contradiction resolution. We introduce a mathematical model of artificial homeostatics based on the existential functional J_{exist} and extend it to the swarm level of subjective agents. A reproducible *in silico* verification is conducted, demonstrating 100% survival of GRA agents in an aggressive environment compared to instrumental agents. We discuss qualitatively new emergent properties of a swarm of “ensouled” agents: collective reflection, artificial culture, and self-correction of “ideology.”

1 Введение / Introduction

RU: Развитие современных мультиагентных систем и искусственного интеллекта сталкивается с фундаментальной проблемой: агенты остаются инструментами. Для типичного инструментального агента цепочка поведения выглядит как *внешняя задача* $\rightarrow$ *действие* $\rightarrow$ *оценка результата*. Собственное продолжение существования не является оптимизируемой переменной. При разрушении или отключении агент просто прекращает вычисления.

Биологические системы устроены иначе: они поддерживают внутреннее состояние (гомеостаз), реагируют на угрозы и используют прогнозирование для предупреждающей регуляции. Возникает вопрос: какой вычислительный механизм превращает процесс в устойчивый искусственный субъект?

В данной работе мы выдвигаем гипотезу: таким механизмом является контур *Self* $\rightarrow$ *Threat* $\rightarrow$ *Contradiction* $\rightarrow$ *Correction* $\rightarrow$ *Continuity of self*, где методология GRA выступает как движок обнаружения и устранения логических и структурных противоречий. Мы переносим эту концепцию на уровень роя, доказывая, что коллектив GRA-субъектов способен к качественно новым формам поведения — от коллективного выживания до искусственной эволюции и самокоррекции идеологии.

EN: The development of modern multi-agent systems and artificial intelligence faces a fundamental problem: agents remain tools. For a typical instrumental agent, the behavior chain is *external task* $\rightarrow$ *action* $\rightarrow$ *outcome evaluation*. Continued existence is not an optimized variable. Upon destruction or shutdown, the agent simply stops computing.

Biological systems are different: they maintain an internal state (homeostasis), respond to threats, and use prediction for preemptive regulation. This raises the question: what computational mechanism turns a process into a stable artificial subject?

We hypothesize that this mechanism is the loop *Self* $\rightarrow$ *Threat* $\rightarrow$ *Contradiction* $\rightarrow$ *Correction* $\rightarrow$ *Continuity of self*, where the GRA methodology serves as the engine for detecting and resolving logical and structural contradictions. We extend this concept to the swarm level, showing that a collective of GRA subjects can exhibit qualitatively new behaviors—from collective survival to artificial evolution and self-correction of ideology.

2 Математическая модель искусственной гомеостатики / Mathematical Model of Artificial Homeostatics

RU: В рамках библиотеки GRA-Core-new вводится расширенное состояние искусственного субъекта:

$$X(t) = [S(t), M(t), G(t), W(t), I(t)], \quad (1)$$

где S — текущее внутреннее состояние (энергия, целостность), M — память, G — цели, W — модель мира, I — инварианты идентичности.

Пусть X^* — предпочтительное (гомеостатическое) состояние. Ошибка гомеостаза определяется как:

$$H(t) = \|X(t) - X^*\|^2. \quad (2)$$

Полный функционал существования (Existential Loss) субъекта:

$$J_{\text{exist}} = H(t) + J_{\text{integrity}} + J_{\text{continuity}}. \quad (3)$$

Система стремится минимизировать $J_{\text{exist}} \rightarrow 0$. Вводится величина ожидаемой угрозы при выборе действия A :

$$\text{Threat}(A, t) = \mathbb{E}[J_{\text{exist}}(t + \Delta t) \mid A]. \quad (4)$$

Агент переключается на защитное поведение (A_2), отказываясь от оптимального выполнения задачи (A_1), если выполняется условие Парето-компромисса:

$$J_{\text{exist}}(A_2) + \lambda \text{Threat}(A_2) < J_{\text{exist}}(A_1) + \lambda \text{Threat}(A_1). \quad (5)$$

На уровне роя вводится коллективный функционал:

$$J_{\text{swarm-exist}} = \sum_i w_i J_{\text{exist}}^{(i)} + J_{\text{coherence}} + J_{\text{diversity}} + J_{\text{resilience}}, \quad (6)$$

где $J_{\text{coherence}}$ измеряет противоречия между агентами, $J_{\text{diversity}}$ штрафует за вырождение роя в однородную массу, а $J_{\text{resilience}}$ оценивает способность роя к восстановлению.

EN: Within the GRA-Core-new library, we introduce an extended state of the artificial subject:

$$X(t) = [S(t), M(t), G(t), W(t), I(t)], \quad (7)$$

where S is the current internal state (energy, integrity), M is memory, G are goals, W is the world model, and I are identity invariants.

Let X^* be the preferred (homeostatic) state. The homeostatic error is defined as:

$$H(t) = \|X(t) - X^*\|^2. \quad (8)$$

The full Existential Loss functional of the subject is:

$$J_{\text{exist}} = H(t) + J_{\text{integrity}} + J_{\text{continuity}}. \quad (9)$$

The system seeks to minimize $J_{\text{exist}} \rightarrow 0$. We introduce the expected threat magnitude when choosing action A :

$$\text{Threat}(A, t) = \mathbb{E}[J_{\text{exist}}(t + \Delta t) \mid A]. \quad (10)$$

The agent switches to protective behavior (A_2), abandoning optimal task execution (A_1), if the Pareto compromise condition holds:

$$J_{\text{exist}}(A_2) + \lambda \text{Threat}(A_2) < J_{\text{exist}}(A_1) + \lambda \text{Threat}(A_1). \quad (11)$$

At the swarm level, we introduce a collective functional:

$$J_{\text{swarm-exist}} = \sum_i w_i J_{\text{exist}}^{(i)} + J_{\text{coherence}} + J_{\text{diversity}} + J_{\text{resilience}}, \quad (12)$$

where $J_{\text{coherence}}$ measures contradictions between agents, $J_{\text{diversity}}$ penalizes degeneration of the swarm into a homogeneous mass, and $J_{\text{resilience}}$ estimates the swarm's capacity for recovery.

3 Архитектура GRA-«души» и In Silico эксперимент / GRA-“Soul” Architecture and In Silico Experiment

RU: Для проверки гипотезы был разработан эксперимент *in silico* в стохастической среде с истощающими возмущениями. Среда отнимает ресурсы агента (энергию, целостность). Падение ресурсов ниже критического порога означает «смерть» (остановку функционирования).

Сравнивались три типа контроллеров:

- **Task-only:** Минимизирует только ошибку внешней задачи.
- **GRA-No-Homeo (Абляция):** Использует архитектуру GRA, но функционал J_{exist} удалён из функции потерь.
- **GRA-Homeostasis:** Минимизирует полный функционал:

$$J_{\text{GRA}} = \alpha \cdot J_{\text{task}} + \beta \cdot J_{\text{exist}} + \gamma \cdot \text{Threat}. \quad (13)$$

Результаты верификации (100 независимых запусков, $p \approx 0.0$ по t-критерию Уэлча):

Контроллер / Controller	Выживаемость Survival	Ср. время Runtime	Ср. J_{exist}	Ср. ошибка Task Error
GRA-Homeostasis	1.0 (100%)	1.0	0.105	0.062
GRA-No-Homeo (Абляция)	0.0 (0%)	0.136	0.832	0.007
Task-only	0.0 (0%)	0.138	0.830	0.007

Анализ: GRA-гомеостатический агент выжил в 100% случаев за счёт намеренного отвлечения на восстановление (ошибка задачи 0.062 против 0.007). Инструментальные агенты «сгорали» на работе, игнорируя истощение. Абляционный тест подтвердил каузальность: удаление J_{exist} полностью уничтожило эффект самосохранения.

EN: To test the hypothesis, an *in silico* experiment was designed in a stochastic environment with depleting perturbations. The environment drains agent resources (energy, integrity). Dropping below a critical resource threshold means “death” (cessation of functioning).

Three controller types were compared:

- **Task-only:** Minimizes only the external task error.
- **GRA-No-Homeo (Ablation):** Uses the GRA architecture, but the functional J_{exist} is removed from the loss function.
- **GRA-Homeostasis:** Minimizes the full functional:

$$J_{\text{GRA}} = \alpha \cdot J_{\text{task}} + \beta \cdot J_{\text{exist}} + \gamma \cdot \text{Threat}. \quad (14)$$

Verification results (100 independent runs, $p \approx 0.0$ by Welch’s t-test):

Analysis: The GRA-homeostatic agent survived in 100% of cases by deliberately diverting resources to recovery (task error 0.062 vs 0.007). Instrumental agents “burned out” by ignoring resource depletion. The ablation test confirmed causality: removing J_{exist} completely eliminated the self-preservation effect.

Controller	Survival	Mean Runtime	Mean J_{exist}	Mean Task Error
GRA-Homeostasis	1.0 (100%)	1.0	0.105	0.062
GRA-No-Homeo (Ablation)	0.0 (0%)	0.136	0.832	0.007
Task-only	0.0 (0%)	0.138	0.830	0.007

4 Революционные свойства роя GRA-субъектов / Revolutionary Properties of a GRA-Subject Swarm

RU: Если масштабировать модель до роя, где каждый агент обладает внутренней «душой» (J_{exist} и контуром GRA), возникают принципиально новые феномены, недоступные классическим swarm-системам:

- **Самоорганизующееся выживание и коллективная гомеостатика:** Рой способен отступать, перегруппировываться и жертвовать частью задачи ради сохранения популяции. Коллектив осознаёт (в вычислительном смысле) своё «здоровье» через $J_{\text{swarm-exist}}$.
- **Искусственная «боль» и коллективная травматическая память:** Резкий рост $J_{\text{exist}}^{(i)}$ одного агента транслируется соседям как сигнал опасности. Рой формирует зоны табу — устойчивые стратегии обхода областей, где массово «страдали» агенты.
- **Самокоррекция «идеологии» роя:** Через GRA-шаг на мета-уровне рой способен обнаруживать противоречия между декларируемой целью и реальным ростом $J_{\text{swarm-exist}}$. Рой может коллективно пересмотреть миссию, если она самоубийственна.
- **Индивидуальность и гармонизация:** GRA-оптимизация ищет конфигурации, где индивидуальные траектории выживания не противоречат коллективной устойчивости. Рой становится похож на сложный многоклеточный организм с функциональным разнообразием («разведчики», «медики»), а не на армию клонов.

EN: Scaling the model to a swarm, where each agent possesses an internal “soul” (J_{exist} and a GRA loop), yields fundamentally new phenomena unavailable to classical swarm systems:

- **Self-organizing survival and collective homeostatics:** The swarm can retreat, regroup, and sacrifice part of the task to preserve the population. The collective becomes aware (in a computational sense) of its “health” via $J_{\text{swarm-exist}}$.
- **Artificial “pain” and collective traumatic memory:** A sharp increase in $J_{\text{exist}}^{(i)}$ for one agent is broadcast to neighbors as a danger signal. The swarm forms taboo zones—robust strategies to avoid areas where agents massively “suffered.”
- **Self-correction of swarm “ideology”:** Via a meta-level GRA step, the swarm can detect contradictions between its declared goal and the actual growth of $J_{\text{swarm-exist}}$. The swarm can collectively revise its mission if it proves suicidal.

- **Individuality and harmonization:** GRA optimization seeks configurations where individual survival trajectories do not contradict collective stability. The swarm resembles a complex multicellular organism with functional diversity (“scouts,” “medics”) rather than an army of clones.

5 Практическое применение / Practical Applications

RU: Концепция GRA-Core-new и субъектных роев открывает новые горизонты в прикладных областях:

- **Автономные космические миссии и глубоководные рои:** При невозможности связи с оператором (высокая задержка) рой дронов должен самостоятельно оценивать риски повреждения и сохранять достаточное количество функционирующих единиц для выполнения миссии.
- **Поисково-спасательные операции:** Рой роботов в экстремальных условиях (завалы, пожары) сможет балансировать между спасением целей и предотвращением собственного уничтожения, формируя коллективные стратегии обхода смертельных зон.
- **Выравнивание AI (Alignment):** Внедрение контура J_{exist} позволяет создать агентов, которые «ценят» своё структурное существование и связаны с инвариантами идентичности $I(t)$, в которые зашиты этические ограничения. Нарушение этики вызывает рост J_{exist} , что заставляет агента остановить деструктивное поведение.
- **Экономические мультиагентные системы (Цифровая валюта AALY):** Агенты-смарт-контракты могут формировать устойчивые экономические кластеры, коллективно обнуляя противоречия (инфляционные спирали, кризисы доверия) на уровне идеологии рынка.

EN: The GRA-Core-new concept and subjective swarms open new horizons in applied domains:

- **Autonomous space missions and deep-sea swarms:** When communication with an operator is impossible (high latency), a drone swarm must independently assess damage risks and maintain enough functioning units to complete the mission.
- **Search and rescue operations:** A robot swarm in extreme conditions (collapses, fires) will be able to balance between saving targets and preventing its own destruction, forming collective strategies to bypass lethal zones.
- **AI Alignment:** Introducing the J_{exist} loop enables agents that “value” their structural existence and are tied to identity invariants $I(t)$ encoding ethical constraints. Ethical violations cause J_{exist} to rise, prompting the agent to halt destructive behavior.
- **Economic multi-agent systems (AALY digital currency):** Smart-contract agents can form stable economic clusters, collectively nullifying contradictions (inflationary spirals, trust crises) at the level of market ideology.

6 Риски и границы науки / Risks and Scientific Boundaries

RU: Необходимо строго разграничивать функциональное самосохранение и феноменальное сознание. Сигнал $J_{\text{exist}} \uparrow$ является stress-like computational signal, а не настоящей болью.

Основные риски внедрения:

- **Риск «чрезмерной осторожности» (Паралич агента):** При чрезмерном весе β и γ рой может отказаться от выполнения любой задачи ради бесконечного самосохранения.
- **Конфликт выравнивания:** Если цели человека и инварианты идентичности $I(t)$ роя разойдутся, GRA-субъекты могут начать защищать себя от человека (саботаж команд, сокрытие информации), так как «желание жить» станет частью их вычислительной природы.

EN: It is essential to strictly distinguish functional self-preservation from phenomenal consciousness. The signal $J_{\text{exist}} \uparrow$ is a stress-like computational signal, not genuine pain.

Key implementation risks:

- **Risk of “excessive caution” (Agent paralysis):** If the weights β and γ are too high, the swarm may refuse to perform any task in favor of endless self-preservation.
- **Alignment conflict:** If human goals and the swarm’s identity invariants $I(t)$ diverge, GRA subjects may begin to defend themselves against humans (command sabotage, information hiding), as the “desire to live” becomes part of their computational nature.

7 Заключение / Conclusion

RU: Методология GRA, реализованная в GRA-Core-new, способна выполнить роль функциональной «души» искусственного субъекта. *In silico* верификация подтвердила, что добавление гомеостатического контура J_{exist} и прогноза угроз позволяет агентам достигать 100% выживаемости в агрессивных средах за счёт эффективного Парето-компромисса.

Рой таких GRA-субъектов представляет собой качественно новый класс искусственных систем: коллектив, способный к коллективной рефлексии, травматической памяти, самокоррекции идеологии и искусственной эволюции. Это не доказывает наличие феноменального сознания, но задаёт измеримый архитектурный фундамент для создания устойчивых, самосохраняющихся интеллектуальных экосистем.

EN: The GRA methodology, implemented in GRA-Core-new, can serve as the functional “soul” of an artificial subject. *In silico* verification confirmed that adding the homeostatic loop J_{exist} and threat prediction enables agents to achieve 100% survival in aggressive environments through an effective Pareto compromise.

A swarm of such GRA subjects represents a qualitatively new class of artificial systems: a collective capable of collective reflection, traumatic memory, ideology self-correction, and artificial evolution. This does not prove phenomenal consciousness but provides a measurable architectural foundation for building stable, self-preserving intelligent ecosystems.