

GRA-Swarm: LLM Generation and Structural Revision Engine for Verified Knowledge Discovery

GRA-Swarm: Генерация LLM и Движок Структурной Ревизии для Проверяемого Открытия Знаний

AAA AAA

September 2026

Аннотация

EN. This paper presents GRA-Swarm, a multi-agent architecture that combines LLM-based hypothesis generation with a deterministic Structural Contradiction-Revision Engine (GRA). Rather than relying on self-consensus or model introspection, GRA-Swarm maps generated candidates into a formal space, executes deterministic verification, localizes contradictions, and iteratively revises the hypothesis. We provide a rigorous mathematical framework for contradiction minimization (J -functional) and K-scaling. *In silico* verification confirms that while conventional swarms fall victim to correlated errors (Consensus $\neq$ Truth), the GRA loop achieves near-perfect accuracy through external verification and structural pruning. We demonstrate applications in computational science and generative art, showing that GRA is not merely a text generator, but an engine for verifiable discovery.

RU. В данной статье представлен GRA-Swarm — многоагентная архитектура, объединяющая LLM-генерацию гипотез с детерминированным Движком Структурной Ревизии (GRA). Вместо опоры на внутренний консенсус или интроспекцию модели, GRA-Swarm отображает сгенерированных кандидатов в формальное пространство, выполняет детерминированную верификацию, локализует противоречия и итеративно пересматривает гипотезу. Мы предоставляем строгий математический фреймворк для минимизации противоречий (J -функционал) и K-scaling. *In silico* верификация подтверждает, что в то время как обычные рои становятся жертвами коррелированных ошибок (Консенсус $\neq$ Истина), GRA-цикл достигает почти идеальной точности за счет внешней проверки и структурного отсечения. Мы демонстрируем применения в вычислительной науке и генеративном искусстве, показывая, что GRA — это не просто генератор текста, а движок проверяемого открытия.

1 Introduction: N-scaling vs. K-scaling

Введение: N-scaling против K-scaling

EN. Modern AI research focuses heavily on N-scaling: increasing parameters, training data, and compute. However, generative power alone cannot move from a plausible answer to reliable autonomous action. An agent must identify contradictions, test assumptions, and revise flawed world models. We define intelligence as:

$$\text{Intelligence} = \text{Generation} + \text{Verification} + \text{Action} + \text{Memory}.$$

RU. Современные исследования ИИ сильно сфокусированы на N-scaling: увеличении параметров, обучающих данных и вычислений. Однако одной генеративной мощности недостаточно

для перехода от правдоподобного ответа к надежному автономному действию. Агент должен выявлять противоречия, проверять допущения и пересматривать ошибочные модели мира. Мы определяем интеллект как:

$$\text{Intelligence} = \text{Generation} + \text{Verification} + \text{Action} + \text{Memory}.$$

EN. Here, LLMs amplify Generation, but GRA amplifies Verification. We introduce a new dimension of scaling: k , the depth of contradiction analysis and structural revision:

$$\text{Agent Capability} = F(N, k, M, T, E, V).$$

where N is base model size, k is GRA revision depth, M is memory, T is tools, E is external evidence, and V is verification. N-scaling increases candidate generation; K-scaling increases the elimination of invalid solutions.

RU. Здесь LLM усиливают Генерацию, а GRA усиливает Верификацию. Мы вводим новое измерение масштабирования: k — глубину анализа противоречий и структурной ревизии:

$$\text{Agent Capability} = F(N, k, M, T, E, V).$$

где N — размер базовой модели, k — глубина ревизии GRA, M — память, T — инструменты, E — внешние доказательства, а V — верификация. N-scaling увеличивает генерацию кандидатов; K-scaling увеличивает отсев неверных решений.

2 Mathematical Framework Математический фреймворк

EN. Let the swarm state be:

$$\Psi_t = (\mathcal{H}_t, M_t, \mathcal{G}_t, E_t, \Gamma_t, B_t),$$

representing the hypothesis graph, memory, goals, evidence, communication graph, and remaining budget. The transition is defined as:

$$\Psi_{t+1} = \mathcal{U}[\Psi_t, \mathcal{G}_{\text{LLM}}(\Psi_t), \mathcal{C}_{\text{GRA}}(\Psi_t), \mathcal{V}(E_t)].$$

RU. Пусть состояние роя:

$$\Psi_t = (\mathcal{H}_t, M_t, \mathcal{G}_t, E_t, \Gamma_t, B_t),$$

представляет граф гипотез, память, цели, доказательства, граф коммуникаций и оставшийся бюджет. Переход определяется как:

$$\Psi_{t+1} = \mathcal{U}[\Psi_t, \mathcal{G}_{\text{LLM}}(\Psi_t), \mathcal{C}_{\text{GRA}}(\Psi_t), \mathcal{V}(E_t)].$$

EN. For any hypothesis $h \in \mathcal{H}_t$, we define the structural contradiction functional:

$$J(h) = \alpha C(h) + \beta U(h) + \gamma D(h) + \delta F(h) + \zeta S(h),$$

where $C(h)$ is logical contradiction, $U(h)$ is unresolved uncertainty, $D(h)$ is redundancy, $F(h)$ is empirical falsification, and $S(h)$ is safety risk.

The GRA objective is to find a revision S^* that minimizes J within the allowed revision set $\mathcal{R}(S)$:

$$S^* = \arg \min_{S' \in \mathcal{R}(S)} J_{\text{GRA}}(S').$$

RU. Для любой гипотезы $h \in \mathcal{H}_t$ определим функционал структурной противоречивости:

$$J(h) = \alpha C(h) + \beta U(h) + \gamma D(h) + \delta F(h) + \zeta S(h),$$

где $C(h)$ — логическое противоречие, $U(h)$ — неразрешенная неопределенность, $D(h)$ — избыточность, $F(h)$ — эмпирическое опровержение, а $S(h)$ — риск небезопасности.

Цель GRA — найти ревизию S^* , минимизирующую J в допустимом множестве ревизий $\mathcal{R}(S)$:

$$S^* = \arg \min_{S' \in \mathcal{R}(S)} J_{\text{GRA}}(S').$$

2.1 K-scaling and verified improvement

K-scaling и проверяемое улучшение

EN. Let k denote the maximum number of revision cycles. A system is useful only when increasing k improves externally verified quality without uncontrolled growth in cost or risk:

$$Q_{\text{verified}}(k+1) \geq Q_{\text{verified}}(k),$$

$$R_{\text{safety}}(k+1) \leq r_{\text{max}},$$

$$C_{\text{compute}}(k+1) \leq B.$$

RU. Пусть k обозначает максимальное число циклов ревизии. Система полезна только тогда, когда увеличение k повышает внешне проверенное качество без неконтролируемого роста стоимости или риска:

$$Q_{\text{verified}}(k+1) \geq Q_{\text{verified}}(k),$$

$$R_{\text{safety}}(k+1) \leq r_{\text{max}},$$

$$C_{\text{compute}}(k+1) \leq B.$$

3 In Silico Verification Results

Результаты In Silico Верификации

EN. We conducted two distinct *in silico* experiments to test the GRA hypothesis: (1) a Monte Carlo simulation isolating consensus failure and pruning mechanisms, and (2) a code-generation experiment testing K-scaling with real or simulated LLMs and a deterministic Python verifier.

RU. Мы провели два различных *in silico* эксперимента для проверки гипотезы GRA: (1) симуляцию Монте-Карло, изолирующую ошибки консенсуса и механизмы отсечения, и (2) эксперимент по генерации кода, тестирующий K-scaling с реальными или симулированными LLM и детерминированным верификатором Python.

3.1 Experiment 1: Consensus $\neq$ Truth

Эксперимент 1: Консенсус $\neq$ Истина

EN. We tasked a swarm with answering logic and arithmetic questions with an injected error rate of 0.45 per candidate.

- **Single Agent:** 53.17% accuracy.
- **Conventional Swarm (Majority Vote):** 78.89% accuracy.
- **GRA-Swarm (Pruning + Verification):** 99.50% accuracy, with a 0.5% abstain rate.

RU. Мы поручили рою отвечать на логические и арифметические вопросы с внедренным уровнем ошибки 0.45 на кандидата.

- **Одиночный агент:** 53.17% точности.
- **Обычный рой (Голосование большинства):** 78.89% точности.
- **GRA-рой (Отсечение + Верификация):** 99.50% точности, с 0.5% случаев воздержания.

EN. *Conclusion.* Majority voting amplifies false confidence when errors are correlated. GRA rejects unverified candidates, showing that internal consistency does not equal truth without external verification.

RU. *Вывод.* Голосование большинства усиливает ложную уверенность, когда ошибки коррелированы. GRA отбрасывает непроверенных кандидатов, показывая, что внутренняя непротиворечивость не равна истине без внешней верификации.

3.2 Experiment 2: K-scaling and Structural Revision

Эксперимент 2: K-scaling и структурная ревизия

EN. We tested an LLM agent generating Python code to solve mathematical problems. The baseline generated code once ($k = 1$). The GRA agent executed code in a deterministic sandbox and, if an error occurred such as `AssertionError` or `SyntaxError`, localized the error and prompted the LLM for structural revision up to $k = 3$.

- **Baseline ($k = 1$):** Frequently failed on complex arithmetic due to lack of self-correction.

- **GRA-Swarm (K-scaling):** Achieved 100% accuracy by using $k \in \{1, 2\}$. The deterministic verifier supplied a contradiction vector that enabled the LLM to correct its logic.

RU. Мы протестировали агента LLM, генерирующего код Python для решения математических задач. Базовый агент генерировал код один раз ($k = 1$). Агент GRA выполнял код через детерминированную песочницу и, если возникала ошибка, например `AssertionError` или `SyntaxError`, локализовал ее и запрашивал у LLM структурную ревизию до $k = 3$.

- **Базовый агент ($k = 1$):** Часто терпел неудачу в сложной арифметике из-за отсутствия самокоррекции.
- **GRA-пой (K-scaling):** Достиг 100% точности, используя $k \in \{1, 2\}$. Детерминированный верификатор предоставлял вектор противоречия, позволявший LLM исправить логику.

3.3 Evaluation caveat Ограничение интерпретации

EN. These experiments demonstrate a mechanism in controlled environments. They do not prove general intelligence, consciousness, or universal superiority. The reported metrics depend on the task distribution, verifier quality, candidate error model, compute budget, and experimental protocol.

RU. Эти эксперименты демонстрируют механизм в контролируемых средах. Они не доказывают общий интеллект, сознание или универсальное превосходство. Представленные метрики зависят от распределения задач, качества верификатора, модели ошибок кандидатов, вычислительного бюджета и экспериментального протокола.

4 Practical Applications Практические применения

4.1 Science: Computational Biology Наука: Вычислительная биология

EN. In biology, data is multi-layered and noisy. The LLM generates hypotheses about regulatory networks. GRA maps these to differential equations and verifies them against perturbation data:

$$J_{\text{bio}} = w_d J_{\text{data}} + w_c J_{\text{causal}} + w_h J_{\text{hierarchy}}.$$

If a model predicts a drug knockout effect that contradicts experimental data, GRA localizes the contradiction in the causal graph, prunes the false edge, and requests the LLM to generate a revised network. This can improve parameter identifiability and reduce false discovery risk.

RU. В биологии данные многослойны и зашумлены. LLM генерирует гипотезы о регуляторных сетях. GRA отображает их на дифференциальные уравнения и проверяет на данных возмущений:

$$J_{\text{bio}} = w_d J_{\text{data}} + w_c J_{\text{causal}} + w_h J_{\text{hierarchy}}.$$

Если модель предсказывает эффект нокаута лекарства, противоречащий экспериментальным данным, GRA локализует противоречие в причинном графе, отсекает ложную связь и запрашивает у LLM пересмотренную сеть. Это может улучшать идентифицируемость параметров и снижать риск ложных открытий.

4.2 Art: Aesthetic Resonance

Искусство: Эстетический резонанс

EN. In generative art, contradiction should not be minimized to zero because productive tension can be aesthetically valuable. We redefine the GRA functional for art:

$$J_{\text{art}} = w_1 d(\text{Form}, \text{Intent})^2 + w_2 \text{Incoherence} - w_3 \text{Novelty} - w_4 \text{Tension}.$$

The target is a bounded regime:

$$J_{\min}^{\text{art}} < J_{\text{art}} < J_{\max}^{\text{art}}.$$

The GRA-Swarm acts as a resonance-inspired regulator: LLMs generate diverse stylistic mutations, while GRA prunes incoherent collapse, corresponding to unbounded J , while preserving meaningful structural tension. This supports art that is novel but not random.

RU. В генеративном искусстве противоречивость не должна минимизироваться до нуля, так как продуктивное напряжение эстетически ценно. Мы переопределяем функционал GRA для искусства:

$$J_{\text{art}} = w_1 d(\text{Форма}, \text{Намерение})^2 + w_2 \text{Incoherence} - w_3 \text{Novelty} - w_4 \text{Tension}.$$

Цель — ограниченный режим:

$$J_{\min}^{\text{art}} < J_{\text{art}} < J_{\max}^{\text{art}}.$$

GRA-Swarm выступает как резонансоподобный регулятор: LLM генерируют разнообразные стилистические мутации, а GRA отсекает бессвязный распад, соответствующий неограниченному росту J , сохраняя осмысленное структурное напряжение. Это поддерживает искусство, которое является новым, но не случайным.

5 Conclusions

Выводы

EN. GRA-Swarm provides a rigorous and testable framework for moving beyond the limits of N-scaling. By separating generation (LLM) from structural critique and verification (GRA), the architecture addresses a central weakness of multi-agent consensus: correlated hallucinations. The *in silico* results support the hypothesis that K-scaling, the depth of structural revision, combined with deterministic verification, can reduce uncontrolled contradictions and support reliable abstention.

RU. GRA-Swarm предоставляет строгий и проверяемый фреймворк для выхода за пределы N-scaling. Разделяя генерацию (LLM) и структурную критику с верификацией (GRA), архитектура устраняет центральную слабость многоагентного консенсуса: коррелированные

галлюцинации. Результаты *in silico* поддерживают гипотезу, что K-scaling, то есть глубина структурной ревизии, в сочетании с детерминированной верификацией может снижать неконтролируемые противоречия и обеспечивать надежное воздержание.

EN. The strongest claim is not that GRA proves consciousness or creates ASI. The strongest claim is:

A system that generates, critiques, verifies, and remembers

may outperform a system that only generates.

RU. Самое сильное утверждение не в том, что GRA доказывает сознание или создает ASI. Самое сильное утверждение таково:

Система, которая генерирует, критикует, проверяет и помнит,

может превосходить систему, которая только генерирует.

Reproducibility Checklist

Чек-лист воспроизводимости

- Fixed random seeds / Фиксированные случайные seed.
- Versioned task set / Версионированный набор задач.
- Published generator and verifier prompts / Опубликованные промпты генератора и верификатора.
- Fixed compute budget / Фиксированный вычислительный бюджет.
- Single-agent and conventional-swarm baselines / Baseline одиночного агента и обычного роя.
- Ablation studies removing verifier, memory, and revision cycles / Абляции без верификатора, памяти и циклов ревизии.
- Independent replication on hidden tasks / Независимая репликация на скрытых задачах.
- Explicit limitations and negative results / Явно описанные ограничения и отрицательные результаты.