

GRA-Physical Remaster: Архитектура и обучение роботов на основе сенсомоторной реконструкции мира

GRA-Physical Remaster: Architecture and Robot Training Based on Sensorimotor World Reconstruction

Аннотация / Abstract

RU. В статье предлагается архитектура GRA-Physical Remaster для обучения физическому искусственному интеллекту (Physical AI), в которой реальный мир рассматривается как частично наблюдаемая, шумная и противоречивая среда. Традиционное обучение политик (RL/IL) в симуляторах сталкивается с *sim-to-real gap*, когда оптимизация чистого вознаграждения не гарантирует устойчивости в реальности. Мы предлагаем объединить методологию GRA (Godel–Reductio ad Absurdum), распределённый слой независимых критиков GRA-RoleMesh, симуляторы NVIDIA Isaac Sim/Lab, физические бэкенды PhysX/Newton и foundation-модели Isaac GR00T. Цель — не обучить «идеальную policy в вакууме», а построить процесс непрерывного обучения, в котором несовпадения между прогнозом и реальным наблюдением измеряются как противоречия, локализуются и используются для структурного пересмотра и адаптивного обновления модели мира и политик управления.

EN. This paper proposes the GRA-Physical Remaster architecture for training Physical AI, in which the real world is treated as a partially observable, noisy, and contradictory environment. Traditional policy training (RL/IL) in simulators faces the *sim-to-real gap*, where optimizing pure reward does not guarantee real-world robustness. We propose combining the GRA (Godel–Reductio ad Absurdum) methodology, a distributed layer of independent critics called GRA-RoleMesh, NVIDIA Isaac Sim/Lab simulators, PhysX/Newton physics backends, and Isaac GR00T foundation models. The goal is not to train a “perfect policy in a vacuum,” but to build a continuous learning process in which mismatches between prediction and real-world observation are measured as contradictions, localized, and used for structural revision and adaptive updating of the world model and control policies.

1 Введение: Проблема обучения в «нечестной» среде / Introduction: The Problem of Training in an “Unfair” Environment

RU. Человек взаимодействует с физическим миром через богатую сенсомоторную петлю. Оценивая вес чашки по первым миллиметрам подъёма и чувствуя проскальзывание, человек мгновенно корректирует силу хвата без явного вычисления физической модели. Для робота, обучаемого в симуляторе (Isaac Sim), реальная среда выглядит как игра со «сломанной механикой». Камера имеет слепые зоны (окклюзия), задержки сети и привода нарушают точность, трение и масса неизвестны, а сенсоры зашумлены. Традиционный end-to-end RL, оптимизирующий награду за успех задачи, часто выучивает хрупкие политики, использующие баги симулятора (*sim2real artifacts*), которые ломаются при переносе в реальность. Отсюда возникает ключевая идея: процессу обучения робота нужен «ремастер» — архитектурный слой, который превращает физические провалы в локализованные, объяснимые и проверяемые обучающие сигналы.

EN. Humans interact with the physical world through a rich sensorimotor loop. By estimating the weight of a cup from the first millimeters of lift and feeling slip, a person instantly corrects the grip force without explicitly computing a physical model. For a robot trained in a simulator (Isaac Sim), the real environment looks like a game with “broken mechanics.” Cameras have blind spots (occlusion), network and actuator delays disrupt accuracy, friction and mass are unknown, and sensors are noisy. Traditional end-to-end RL, optimizing reward for task success, often learns fragile policies that exploit simulator bugs (sim2real artifacts), which break upon transfer to reality. This leads to the key idea: the robot training process needs a “remaster” — an architectural layer that transforms physical failures into localized, explainable, and verifiable learning signals.

2 NVIDIA Physical AI как инфраструктура для обучения / NVIDIA Physical AI as a Training Infrastructure

RU. NVIDIA Isaac предоставляет физически обоснованную инфраструктуру для RL, imitation learning (IL) и motion planning. Isaac Lab используется для массового обучения политик. Newton (дифференцируемый физический движок) позволяет вычислять градиенты противоречий по параметрам:

$$\frac{\partial J_{\text{physical}}}{\partial u_t}, \quad \frac{\partial J_{\text{physical}}}{\partial \theta_{\text{physics}}}$$

где u_t — действие, θ_{physics} — скрытые параметры (трение, масса). Это позволяет не просто обучать policy, но и проводить system identification (идентификацию параметров среды) в реальном времени. Isaac GR00T выступает как высокоуровневая VLA-модель (Vision-Language-Action), предлагающая семантические навыки, которые должны быть валидированы нижестоящими слоями.

EN. NVIDIA Isaac provides a physically grounded infrastructure for RL, imitation learning (IL), and motion planning. Isaac Lab is used for massive policy training. Newton (a differentiable physics engine) allows computing gradients of contradictions with respect to parameters:

$$\frac{\partial J_{\text{physical}}}{\partial u_t}, \quad \frac{\partial J_{\text{physical}}}{\partial \theta_{\text{physics}}}$$

where u_t is the action and θ_{physics} represents hidden parameters (friction, mass). This allows not only training a policy but also performing system identification in real-time. Isaac GR00T acts as a high-level VLA (Vision-Language-Action) model, offering semantic skills that must be validated by downstream layers.

3 Формальная модель обучения GRA / Formal GRA Training Model

RU. Робот поддерживает вероятностное belief-состояние:

$$b_t(x) = p(x_t \mid o_{1:t}, u_{1:t-1})$$

Компактное латентное состояние z_t обучается предсказывать следующее состояние и наблюдение:

$$z_t = f_{\theta}(z_{t-1}, o_t, u_{t-1}), \quad (\hat{z}_{t+1}, \hat{o}_{t+1}) = F_{\theta}(z_t, u_t)$$

В процессе обучения минимизируется функция ошибки предсказания, однако вместо усредненной MSE вводится структурированный вектор физической «пены» (противоречий).

EN. The robot maintains a probabilistic belief state:

$$b_t(x) = p(x_t \mid o_{1:t}, u_{1:t-1})$$

The compact latent state z_t is trained to predict the next state and observation:

$$z_t = f_\theta(z_{t-1}, o_t, u_{t-1}), \quad (\hat{z}_{t+1}, \hat{o}_{t+1}) = F_\theta(z_t, u_t)$$

During training, the prediction error function is minimized, but instead of averaged MSE, a structured vector of physical “foam” (contradictions) is introduced.

4 Вектор противоречий как обучающий сигнал / Contradiction Vector as a Learning Signal

RU.

$$c_t = [c_{\text{perception}} \quad c_{\text{contact}} \quad c_{\text{dynamics}} \quad c_{\text{body}} \quad c_{\text{task}} \quad c_{\text{sim2real}} \quad c_{\text{safety}}]^T$$

Каждая компонента отражает расхождение между предсказанием world model и реальным/симулированным наблюдением. Например, c_{contact} — ошибка тактильного предсказания (проскальзывание), c_{sim2real} — расхождение между поведением политики в симуляторе и на реальном роботе. Функционал потерь при обучении политики принимает вид:

$$J_{\text{physical}}(t) = \sum_{k=1}^K w_k c_{k,t}^2 + \lambda_{\text{energy}} E_t + \lambda_{\text{damage}} D_t + \lambda_{\text{risk}} \mathcal{R}_t$$

EN.

$$c_t = [c_{\text{perception}} \quad c_{\text{contact}} \quad c_{\text{dynamics}} \quad c_{\text{body}} \quad c_{\text{task}} \quad c_{\text{sim2real}} \quad c_{\text{safety}}]^T$$

Each component reflects the discrepancy between the world model’s prediction and the real/simulated observation. For example, c_{contact} is a tactile prediction error (slip), and c_{sim2real} is the discrepancy between the policy’s behavior in the simulator and on the real robot. The loss function for policy training takes the form:

$$J_{\text{physical}}(t) = \sum_{k=1}^K w_k c_{k,t}^2 + \lambda_{\text{energy}} E_t + \lambda_{\text{damage}} D_t + \lambda_{\text{risk}} \mathcal{R}_t$$

5 GRA-RoleMesh для физического ИИ: Независимое обучение критиков / GRA-RoleMesh for Physical AI: Independent Critic Training

RU. Вместо того чтобы обучать одну нейросеть оценивать качество действия, GRA-RoleMesh разделяет источники ошибок, обучая структурно независимых критиков (ансамбль):

1. **VisionCritic** — обучен на RGB-D данных, оценивает корректность сегментации и позы.
2. **ContactCritic** — обучен на тактильных массивах и F/T-сенсорах, оценивает стабильность хвата.
3. **PhysicsCritic** — использует rollouts в Newton/PhysX для верификации динамики.
4. **SafetyCritic** — оперирует жесткими ограничениями (hard constraints): $\Pr(\text{unsafe} \mid z_t, u_t) \leq \delta$.

Критики обучаются на разных модальностях с пониженной корреляцией ошибок:

$$\frac{1}{M(M-1)} \sum_{i \neq j} |\text{Corr}(e_i, e_j)| < \gamma_{\max}$$

EN. Instead of training a single neural network to evaluate action quality, GRA-RoleMesh separates error sources by training structurally independent critics (an ensemble):

1. **VisionCritic** — trained on RGB-D data, evaluates segmentation and pose correctness.
2. **ContactCritic** — trained on tactile arrays and F/T sensors, evaluates grasp stability.
3. **PhysicsCritic** — uses rollouts in Newton/PhysX to verify dynamics.
4. **SafetyCritic** — operates with hard constraints: $\Pr(\text{unsafe} \mid z_t, u_t) \leq \delta$.

Critics are trained on different modalities with reduced error correlation:

$$\frac{1}{M(M-1)} \sum_{i \neq j} |\text{Corr}(e_i, e_j)| < \gamma_{\max}$$

6 Протокол обучения Sim-to-Real (GRA-Driven) / Sim-to-Real Training Protocol (GRA-Driven)

RU. Традиционный sim-to-real использует Domain Randomization (DR). GRA вводит адаптивное обучение. Пусть θ — параметры рандомизации (освещение, трение, масса). Вместо равномерного выбора, распределение обновляется в сторону наиболее проблемных классов противоречий, выявленных на реальном роботе:

$$p_{t+1}(\theta) \propto p_t(\theta) \exp(\eta \cdot \text{Sim2RealError}(\theta))$$

Если реальный робот постоянно роняет мокрые стаканы (высокий c_{contact}), симулятор начинает генерировать больше сцен с мокрыми поверхностями, фокусируя вычислительный бюджет RL на решении именно этой проблемы.

Архитектурный контур обучения:

1. **Этап А (Sim Pretraining):** В Isaac Lab обучается политика $\pi_\phi(u_t \mid z_t, \text{goal})$. Целевая функция RL: $\max_\phi \mathbb{E}[R_{\text{task}} - \lambda J_{\text{physical}}]$. Политика штрафует за высокую пену, что заставляет её выбирать плавные, безопасные траектории.
2. **Этап В (Real Deployment & Logging):** На реальном роботе запускается ограниченный набор безопасных задач. Логируется датасет расхождений: $\mathcal{D}_{\text{real}} = \{(o_t, u_t, c_t, \text{outcome}_t)\}$.
3. **Этап С (Counterfactual Training):** Sim2RealCritic строит карту расхождений Δ_{sim2real} . Isaac Sim запускает контрфактические rollouts для поиска гипотезы ω^* (например, скрытой массы), лучше объясняющей реальное наблюдение:

$$\omega^* = \arg \min_{\omega \in \Omega_t} D(o_{t+1}^{\text{real}}, \text{Sim}(z_t, u_t; \omega))$$

4. **Этап D (GRA-Guided Simulator Update):** Вместо переобучения с нуля, обновляется латентное пространство world model и параметры симулятора:

$$\theta_{\text{sim}}^{(n+1)} = \theta_{\text{sim}}^{(n)} - \eta \nabla_{\theta_{\text{sim}}} J_{\text{sim2real}}$$

EN. Traditional sim-to-real uses Domain Randomization (DR). GRA introduces adaptive training. Let θ be the randomization parameters (lighting, friction, mass). Instead of uniform sampling, the distribution is updated towards the most problematic classes of contradictions identified on the real robot:

$$p_{t+1}(\theta) \propto p_t(\theta) \exp(\eta \cdot \text{Sim2RealError}(\theta))$$

If the real robot repeatedly drops wet glasses (high c_{contact}), the simulator starts generating more scenes with wet surfaces, focusing the RL compute budget on solving exactly this problem.

Architectural training loop:

1. **Stage A (Sim Pretraining):** A policy $\pi_\phi(u_t | z_t, \text{goal})$ is trained in Isaac Lab. The RL objective: $\max_\phi \mathbb{E}[R_{\text{task}} - \lambda J_{\text{physical}}]$. The policy is penalized for high foam, forcing it to choose smooth, safe trajectories.
2. **Stage B (Real Deployment & Logging):** A restricted set of safe tasks is executed on the real robot. A dataset of mismatches is logged: $\mathcal{D}_{\text{real}} = \{(o_t, u_t, c_t, \text{outcome}_t)\}$.
3. **Stage C (Counterfactual Training):** Sim2RealCritic constructs a mismatch map Δ_{sim2real} . Isaac Sim runs counterfactual rollouts to find a hypothesis ω^* (e.g., hidden mass) that best explains the real observation:

$$\omega^* = \arg \min_{\omega \in \Omega_t} D(o_{t+1}^{\text{real}}, \text{Sim}(z_t, u_t; \omega))$$

4. **Stage D (GRA-Guided Simulator Update):** Instead of retraining from scratch, the latent space of the world model and simulator parameters are updated:

$$\theta_{\text{sim}}^{(n+1)} = \theta_{\text{sim}}^{(n)} - \eta \nabla_{\theta_{\text{sim}}} J_{\text{sim2real}}$$

7 Иерархическое обучение мелкой моторики / Hierarchical Training of Fine Motor Skills

RU. Язык и VLA (например, GR00T) задают цель, но мелкая моторика требует частоты реакции в миллисекунды. Архитектура обучается как трёхуровневая иерархия:

VLA task policy $\rightarrow$ model-predictive skill controller (MPC) $\rightarrow$ fast tactile reflex controller

Нижний уровень (тактильный рефлекс) обучается через RL с использованием impedance control:

$$F_{\text{cmd}} = K_p(x_{\text{target}} - x) + K_d(\dot{x}_{\text{target}} - \dot{x})$$

GRA-слой выступает как мета-обучаемый регулятор: если c_{contact} растёт (предмет скользит), GRA увеличивает K_p вдоль нужной оси. Если c_{safety} растёт (риск перелома), GRA принудительно ограничивает силу захвата:

$$F_{t+\Delta t} = \text{clip}(F_t + k_s s_t - k_o \max(0, F_t - F_{\text{safe}})).$$

EN. Language and VLA (e.g., GR00T) define the goal, but fine motor skills require response rates in milliseconds. The architecture is trained as a three-level hierarchy:

VLA task policy $\rightarrow$ model-predictive skill controller (MPC) $\rightarrow$ fast tactile reflex controller

The lower level (tactile reflex) is trained via RL using impedance control:

$$F_{\text{cmd}} = K_p(x_{\text{target}} - x) + K_d(\dot{x}_{\text{target}} - \dot{x})$$

The GRA layer acts as a meta-learnable regulator: if c_{contact} grows (object is slipping), GRA increases K_p along the required axis. If c_{safety} grows (risk of breaking), GRA forcibly limits the grip force:

$$F_{t+\Delta t} = \text{clip}(F_t + k_s s_t - k_o \max(0, F_t - F_{\text{safe}})).$$

8 Пример обучения: Задача «взять хрупкий стакан» / Training Example: “Pick up a fragile glass”

RU. Постановка обучения: Агент должен перенести стакан в сушилку. В симуляторе он обучен успешно выполнять задачу. При переносе в реальность:

1. VisionCritic фиксирует $c_{\text{perception}} > 0$: контур стакана нестабилен из-за бликов. Предлагает Δ_1 : reobserve (сменить ракурс).
2. ContactCritic фиксирует $c_{\text{contact}} > 0$: давление на пальцах несимметрично. Предлагает Δ_2 : regrasp (перехват).
3. SafetyCritic фиксирует риск столкновения со стойкой сушилки. Включает veto на текущую траекторию.

Вместо того чтобы уронить стакан (собрать отрицательную награду в реальности, что дорого и небезопасно), GRA-движок пересмотра выбирает безопасную последовательность действий на основе оценок критиков:

$$u^* = u_{\text{reobserve}} \rightarrow u_{\text{regrasp}} \rightarrow u_{\text{lift slowly}} \rightarrow u_{\text{transport upright}}$$

Этот эпизод логируется и используется для дообучения (fine-tuning) VLA-модели в Isaac Sim.

EN. Training setup: The agent must transport a glass to a drying rack. It is trained to perform the task successfully in simulation. Upon transfer to reality:

1. VisionCritic detects $c_{\text{perception}} > 0$: glass contour is unstable due to glare. Suggests Δ_1 : reobserve (change viewpoint).
2. ContactCritic detects $c_{\text{contact}} > 0$: finger pressure is asymmetrical. Suggests Δ_2 : regrasp.
3. SafetyCritic detects a risk of collision with the drying rack. Triggers a veto on the current trajectory.

Instead of dropping the glass (collecting a negative reward in reality, which is expensive and unsafe), the GRA revision engine selects a safe sequence of actions based on critic evaluations:

$$u^* = u_{\text{reobserve}} \rightarrow u_{\text{regrasp}} \rightarrow u_{\text{lift slowly}} \rightarrow u_{\text{transport upright}}$$

This episode is logged and used for fine-tuning the VLA model in Isaac Sim.

9 Выводы / Conclusions

RU. GRA-Physical Remaster предлагает парадигмальный сдвиг в обучении роботов: переход от максимизации локального вознаграждения к минимизации сенсомоторных противоречий. NVIDIA Isaac Sim, Newton и GR00T предоставляют инфраструктуру, где Newton/PhysX генерирует дифференцируемые траектории для оценки физической пены; Isaac Replicator осуществляет адаптивную, а не слепую domain randomization, фокусируясь на классах задач с максимальным sim2real gap; GR00T декомпозирует семантические цели, валидируемые нижестоящими GRA-критиками. В узких задачах (микросборка, лабораторная автоматизация) такая система обучения способна превзойти человека по точности и повторяемости. Однако для обобщения в открытом мире необходимы эмпирические тесты с реальными тактильными сенсорами и строгая оценка независимости критиков.

EN. GRA-Physical Remaster proposes a paradigm shift in robot training: moving from maximizing local reward to minimizing sensorimotor contradictions. NVIDIA Isaac Sim, Newton,

and GR00T provide the infrastructure where Newton/PhysX generates differentiable trajectories to evaluate physical foam; Isaac Replicator performs adaptive, rather than blind, domain randomization, focusing on task classes with the maximum sim2real gap; GR00T decomposes semantic goals validated by downstream GRA critics. In narrow tasks (micro-assembly, lab automation), such a training system can surpass humans in precision and repeatability. However, generalization in the open world requires empirical tests with real tactile sensors and rigorous evaluation of critic independence.

Дисклеймер / Disclaimer

RU. Предложенная архитектура и методы обучения описывают математическую модель и программную инфраструктуру. Они не доказывают наличие у робота субъективных чувств, сознания или человеческой интуиции, а демонстрируют лишь алгоритмическое управление вектором функционального состояния для минимизации ошибок управления.

EN. The proposed architecture and training methods describe a mathematical model and software infrastructure. They do not prove the robot’s possession of subjective feelings, consciousness, or human intuition, but merely demonstrate algorithmic control of a functional state vector to minimize control errors.