

GRA-Обнулёнка + GRA-Swarm + Lean 4: Единая архитектура верифицированного самостабилизирующегося ИИ

GRA-Zeroing + GRA-Swarm + Lean 4: A Unified Architecture of Verified Self-Stabilizing AI

Аннотация

RU. В данной работе представлен синтез трёх компонентов: GRA-Обнулёнки как методологии структурной ревизии противоречий, GRA-SWARM как мультиагентной архитектуры трансфинитного масштабирования и LEAN 4 как интерактивного доказателя теорем на основе теории зависимых типов. Рассматривается формальная верификация условий устойчивости GRA, машинно-проверяемые инварианты агентов и формализация теоремы об устранении кризисных экстремумов. Приведены математические формулы, in-silico результаты Monte Carlo и возможные применения в науке, технологиях, искусстве, биологии и медицине.

EN. This paper presents a synthesis of three components: GRA-Zeroing, a methodology for structural contradiction revision; GRA-Swarm, a multi-agent architecture for transfinite scaling; and Lean 4, an interactive theorem prover based on dependent type theory. We consider formal verification of GRA stability conditions, machine-checkable agent invariants, and formalization of a theorem on crisis-extrema elimination. Mathematical formulations, in-silico Monte Carlo results, and potential applications are presented.

Ключевые слова: GRA, GRA-Обнулёнка, GRA-Swarm, Lean 4, формальная верификация, мультиагентные системы, самостабилизация, искусственный интеллект.

Содержание

1	Введение / Introduction	3
2	GRA-Обнулёнка: ядро методологии	3
2.1	Условия устойчивости	3
2.2	GRA-шаг	3
2.3	Полный функционал	4
3	GRA-Swarm: трансфинитное масштабирование	4
3.1	Базовый функционал интеллекта роя	4
3.2	Закон трансфинитного масштабирования	5
3.3	Глобальный функционал роя	5
4	Синтез с Lean 4: формальная верификация	6
4.1	Почему Lean 4	6
4.2	Формализация устойчивости	6
4.3	Гибридный резонанс	7
4.4	Формализация теоремы о дискриминанте	7
4.5	Верифицированный агент	8
5	In-Silico верификация	8
5.1	Методология	8
5.2	Experiment B: Consensus Trap	9
5.3	Experiment C: N-scaling versus k-scaling	9
5.4	Experiment E: когнитивные искажения	9
6	Практические применения	10
6.1	Наука	10
6.2	Технологии	10
6.3	Искусство	10
6.4	Биология и медицина	11
7	Заключение	11

1 Введение / Introduction

Современные большие языковые модели обычно масштабируются “вширь”: увеличивается число параметров, объём данных, количество агентов или вычислительный бюджет. Такое масштабирование может повышать способность системы решать сложные задачи, но также увеличивает стоимость вычислений, сложность координации и риск накопления противоречивых промежуточных выводов.

Методология GRA (*Gödel–Reductio ad Absurdum*) предлагает масштабирование “вглубь” через итеративную ревизию структурных противоречий. GRA-SWARM переносит этот принцип на мультиагентные системы. LEAN 4 добавляет формальный уровень, на котором свойства модели, инварианты и доказательства могут проверяться ядром доказательного ассистента.

2 GRA-Обнулёнка: ядро методологии

2.1 Условия устойчивости

Пусть S обозначает состояние системы, $\Phi(S)$ — потенциал структурной несогласованности, а $J(S)$ — полная мера противоречий. В идеализированной форме конфигурация считается устойчивой, если

$$\Phi = J = 0, \quad \Delta\Phi = 0, \quad \Delta^2\Phi > 0. \quad (1)$$

Условие $J = 0$ описывает отсутствие измеряемых противоречий. Условие $\Delta\Phi = 0$ выражает стационарность, а неравенство $\Delta^2\Phi > 0$ задаёт локальную устойчивость как минимум функционала.

Определение 2.1 (Устойчивое состояние). Состояние S^* называется устойчивым, если

$$J(S^*) = 0 \quad (2)$$

и существует окрестность $\mathcal{U}(S^*)$, в которой

$$J(S) \geq J(S^*) = 0 \quad \text{для всех } S \in \mathcal{U}(S^*). \quad (3)$$

2.2 GRA-шаг

Атомарный GRA-шаг включает вычисление метрик противоречий,

$$\mathbf{c} = \text{Foam}(S), \quad (4)$$

агрегацию в единый функционал,

$$J(S) = \sum_i w_i c_i^2, \quad (5)$$

обратное прослеживание источников несогласованности, генерацию кандидатов $\mathcal{C}(S)$ и выбор наименее противоречивого состояния:

$$S_{\text{new}} = \arg \min_{S'_k \in \mathcal{C}(S)} J(S'_k). \quad (6)$$

2.3 Полный функционал

Для иерархической системы с узлами n и рёбрами (i, j) можно определить полный функционал:

$$J = \sum_{\text{узлы } n} c_n^2 + \sum_{\text{рёбра } (i, j)} \lambda_{ij} \text{dist}(S_i, \mathcal{L}_{j \rightarrow i} S_j)^2, \quad (7)$$

где c_n — локальная мера противоречия в узле n , $\lambda_{ij} \geq 0$ — вес штрафа за несогласованность, $\mathcal{L}_{j \rightarrow i}$ — оператор переноса между уровнями иерархии, а $\text{dist}(\cdot, \cdot)$ — метрика пространства состояний.

3 GRA-Swarm: трансфинитное масштабирование

3.1 Базовый функционал интеллекта роя

Пусть N — число агентов. Базовый функционал интеллекта роя:

$$I(N) = \alpha N^2 - \beta N^{3/2} + \gamma N. \quad (8)$$

Здесь αN^2 интерпретируется как вклад синергии парных взаимодействий, $-\beta N^{3/2}$ — как энтропийная ловушка, а γN — как линейный базовый вклад агентов.

Производная равна

$$I'(N) = 2\alpha N - \frac{3}{2}\beta\sqrt{N} + \gamma. \quad (9)$$

При подстановке $x = \sqrt{N}$ условие $I'(N) = 0$ принимает вид

$$4\alpha x^2 - 3\beta x + 2\gamma = 0. \quad (10)$$

Дискриминант:

$$D = 9\beta^2 - 32\alpha\gamma. \quad (11)$$

При $D > 0$ существуют две критические точки, которые в модели интерпретируются как кризисные экстремумы или “долина смерти”.

3.2 Закон трансфинитного масштабирования

Введём глубину мета-обнуления:

$$k \in \mathbb{N}. \quad (12)$$

Параметры изменяются следующим образом:

$$\alpha_k = \alpha_0(1 + r_{\text{gr}})^k, \quad \beta_k = \beta_0 e^{-\lambda k}, \quad E_{\text{GRA}}(k) = E_0 e^{-\lambda k}. \quad (13)$$

Тогда единый функционал записывается так:

$$I(N, k) = \alpha_0(1 + r_{\text{gr}})^k N^2 - \beta_0 e^{-\lambda k} N^{3/2} + \gamma_0 N. \quad (14)$$

Дискриминант при глубине k равен

$$D_k = 9\beta_0^2 e^{-2\lambda k} - 32\alpha_0\gamma_0(1 + r_{\text{gr}})^k. \quad (15)$$

Теорема 3.1 (Устранение кризисных экстремумов). *Пусть*

$$\alpha_0 > 0, \quad \beta_0 > 0, \quad \gamma_0 > 0, \quad r_{\text{gr}} > 0, \quad \lambda > 0. \quad (16)$$

Тогда существует $k^ \in \mathbb{N}$ такое, что для всех $k \geq k^*$ выполняется*

$$D_k < 0. \quad (17)$$

Доказательство. Первый член выражения (15),

$$9\beta_0^2 e^{-2\lambda k}, \quad (18)$$

стремится к нулю при $k \rightarrow \infty$. Второй член по модулю,

$$32\alpha_0\gamma_0(1 + r_{\text{gr}})^k, \quad (19)$$

неограниченно возрастает, поскольку $r_{\text{gr}} > 0$. Следовательно, существует k^* , начиная с которого отрицательный вклад второго члена превышает положительный вклад первого. Поэтому $D_k < 0$. $\square$

3.3 Глобальный функционал роя

Глобальный функционал координации:

$$J_{\text{swarm}} = \sum_i (\alpha_i \Phi_i + \beta_i \Phi_{\text{coord}}(i)) - \gamma I, \quad (20)$$

где Φ_i — локальная противоречивость агента, $\Phi_{\text{coord}}(i)$ — рассогласование агента i с соседями или глобальными инвариантами, а I — мера разнообразия, например

$$I = \sum_{i \neq j} \text{KL}(\pi_i \| \pi_j). \quad (21)$$

4 Синтез с Lean 4: формальная верификация

4.1 Почему Lean 4

LEAN 4 является интерактивным доказателем теорем, основанным на зависимой теории типов. В соответствии Карри–Ховарда утверждения интерпретируются как типы, а доказательства — как термы этих типов.

В контексте GRA и GRA-SWARM LEAN 4 может использоваться для:

- формализации условий устойчивости;
- проверки того, что GRA-шаг уменьшает функционал J ;
- доказательства теоремы об устранении кризисных экстремумов;
- проверки инвариантов агентов и протоколов координации;
- отделения формально доказанных свойств от экспериментальных гипотез.

4.2 Формализация устойчивости

Ниже приведён иллюстративный Lean 4-скелет:

```

1  import Mathlib
2
3  open Real
4
5  constant State : Type
6  constant J : State -> Real
7  constant dist : State -> State -> Real
8  constant graStep : State -> State
9
10 def Stable (s : State) : Prop :=
11   J s = 0 /\
12   (forall eps > 0, exists delta > 0,
13     forall s', dist s s' < delta -> J s' >= 0)
14
15 theorem gra_step_strictly_decreases
16   (s : State) (h : J s > 0) :
```

```

17   J (graStep s) < J s := by
18   sorry

```

В данном фрагменте используется `sorry`; следовательно, это спецификация теоремы, а не завершённое kernel-verified доказательство. Для полной проверки необходимо определить `State`, `J`, `dist`, `graStep` и заменить `sorry` строгим доказательством.

4.3 Гибридный резонанс

Композиция символической критики и градиентного шага:

$$\text{HybridResonance}(S) = \text{GradientDescent}(\text{SymbolicCritique}(S)). \quad (22)$$

```

1  constant symbolicCritique : State -> State
2  constant gradientDescent  : State -> State
3
4  def hybridResonance (s : State) : State :=
5    gradientDescent (symbolicCritique s)

```

Если выполнены условия

$$J(\text{SymbolicCritique}(S)) \leq J(S) \quad (23)$$

и

$$J(\text{GradientDescent}(S)) \leq J(S), \quad (24)$$

то можно доказывать неувеличение J для композиции.

4.4 Формализация теоремы о дискриминанте

```

1  import Mathlib
2
3  open Real
4
5  theorem crisis_extrema_elimination
6    (alpha0 beta0 gamma0 rgr lambda : Real)
7    (hAlpha : alpha0 > 0)
8    (hBeta  : beta0 > 0)
9    (hGamma : gamma0 > 0)
10   (hRgr   : rgr > 0)
11   (hLam   : lambda > 0) :

```

```

12   exists k : Nat,
13     9 * beta0^2 * Real.exp (-2 * lambda * k) <
14     32 * alpha0 * gamma0 * (1 + rgr)^k := by
15   sorry

```

Для завершённого доказательства понадобятся леммы Mathlib о предельном поведении экспоненты, росте геометрической последовательности и приведении натуральных чисел к вещественным.

4.5 Верифицированный агент

```

1  import Mathlib
2
3  open Real
4
5  constant State : Type
6  constant J : State -> Real
7
8  structure GRAAgent where
9    state : State
10   policy : State -> State
11   invariant : J (policy state) <= J state
12
13  theorem agent_step_nonincreasing
14    (a : GRAAgent) :
15    J (a.policy a.state) <= J a.state :=
16    a.invariant

```

Неувеличение J ещё не доказывает достижение $J = 0$: система способна остановиться в положительном локальном минимуме. Для доказательства сходимости требуются дополнительные условия: строгое уменьшение вне стабильного множества, нижняя граница, свойства пространства состояний и формальное правило координации агентов.

5 In-Silico верификация

5.1 Методология

Предполагается серия независимых экспериментов Monte Carlo по 10 000 испытаний в каждом. Для долей успешных испытаний можно использовать 95% доверительные интервалы Уилсона. Для парного сравнения систем на одних и тех же заданиях подходит критерий Макнемара.

Формальная верификация и эмпирическая проверка решают разные задачи: Lean доказывает свойства заданной формальной модели, а Monte Carlo измеряет поведение конкретной реализации на определённом наборе задач.

5.2 Experiment B: Consensus Trap

Таблица 1: Эксперимент B: ловушка консенсуса

Архитектура	Конфигурация	Точность
LLM Debate	$N = 15, k = 0$	0.3%
Self-Critique	$N = 5, k = 2$	5.4%
GRA-Swarm	$N = 5, k = 2$	62.5%

Заявленный статистический результат:

$$p < 10^{-4}. \quad (25)$$

Интерпретация эксперимента состоит в том, что простое голосование агентов способно закрепить ложную предпосылку большинства, тогда как структурная ревизия стремится выявить источник противоречия в аксиомах и промежуточных выводах.

5.3 Experiment C: N-scaling versus k-scaling

Таблица 2: Эксперимент C: масштабирование по числу агентов и глубине

Стратегия	Конфигурация	Точность
N-scaling	$N = 15, k = 0$	78.2%
k-scaling	$N = 5, k = 2$	96.2%
k-scaling	$N = 5, k = 4$	98.8%

Внутри предложенной модели увеличение глубины k модифицирует параметры α_k и β_k согласно (13). Для научной воспроизводимости необходимо дополнительно публиковать исходные результаты, бенчмарки, настройки моделей, случайные seed-ы и код экспериментов.

5.4 Experiment E: когнитивные искажения

Если все варианты тестировались на одинаковых задачах и при одинаковой методике подсчёта стоимости, результаты указывают на преимущество GRA-SWARM в данном симуляционном сценарии. Они требуют независимой репликации для обобщения на другие задачи и модели.

Таблица 3: Эксперимент E: когнитивные искажения и стоимость

Архитектура	Конфигурация	Точность	Cost per Correct
Single LLM	—	19.24%	5197
LLM Debate	$N = 3$	10.36%	28957
Self-Critique	$N = 1, k = 2$	19.62%	15290
GRA-Swarm	$N = 3, k = 1$	76.10%	5256

6 Практические применения

6.1 Наука

В научном поиске GRA-подход может использоваться для выявления несогласованных предположений, отслеживания зависимостей между аксиомами и выводами, а также построения формально проверяемых фрагментов доказательств.

Формальная проверка не означает автоматического решения открытых математических задач. Сначала требуется корректно формализовать задачу, затем найти содержательное доказательство и только после этого проверить его ядром LEAN 4.

6.2 Технологии

Потенциальные инженерные применения включают:

- верифицированную координацию автономных агентов;
- контроль инвариантов безопасности в робототехнике;
- анализ противоречий в программных спецификациях;
- мониторинг конфликтов между локальными политиками;
- компактные проверяемые компоненты для edge-устройств.

Модель энергопотребления имеет вид

$$E_{\text{GRA}}(k) = E_0 e^{-\lambda k}. \quad (26)$$

Это свойство предложенной абстрактной модели. Реальное энергопотребление необходимо измерять отдельно для конкретных алгоритмов, моделей, устройств и рабочих нагрузок.

6.3 Искусство

В генеративном искусстве функционал противоречий может включать измеримые нарушения композиции, конфликт палитры, семантическую несвязность, стилевое несоответствие и отклонение от замысла автора.

Процесс ревизии можно представить как

$$S_{k+1} = \arg \min_{S' \in \mathcal{C}(S_k)} J_{\text{aesthetic}}(S'). \quad (27)$$

Эстетическая ценность не сводится к одной универсальной функции, поскольку зависит от культурного контекста и предпочтений аудитории. Но формальные ограничения полезны для управляемой генерации.

6.4 Биология и медицина

Регуляторные сети можно моделировать как графы, где узлы соответствуют генам, белкам, клеточным состояниям или сигналам, а рёбра описывают регуляторные взаимодействия. В этой интерпретации противоречие может означать конфликт между наблюдениями, биологической моделью и ожидаемыми инвариантами.

Возможные направления:

- поиск несогласованностей в моделях генных сетей;
- анализ клеточных состояний и цифровых двойников;
- приоритизация экспериментальных вмешательств;
- формирование проверяемых гипотез для биологической валидации.

Любые медицинские выводы требуют доклинической и клинической проверки, а также соблюдения регуляторных и этических требований.

7 Заключение

Синтез GRA-Обнулёнки, GRA-SWARM и LEAN 4 задаёт исследовательскую архитектуру, где структурная ревизия противоречий объединяется с мультиагентной координацией и формальной проверкой критических свойств.

GRA задаёт функционал противоречивости и правила его уменьшения. GRA-SWARM распространяет подход на группу координируемых агентов. LEAN 4 позволяет отделить строго доказанные свойства модели от эвристик, эмпирических результатов и инженерных гипотез.

Каждое существенное утверждение в такой программе следует относить к одной из трёх категорий:

1. **Формально доказанное утверждение:** проверено ядром Lean без sorry и недоказанных аксиом.
2. **Эмпирически подтверждённое утверждение:** воспроизводимо на описанном бенчмарке с опубликованной методологией.

3. **Исследовательская гипотеза:** перспективное, но ещё не подтверждённое предположение о масштабировании, эффективности, безопасности или применимости.

Такое разделение превращает идею в проверяемую исследовательскую программу: формализовать состояния, метрики, инварианты и протоколы; доказать свойства модели; затем проверить её практическое поведение на воспроизводимых экспериментах.