GRA-Обнулёнка и Lean 4: единая архитектура верифицированного самостабилизирующегося интеллекта и её квантово-информационный изоморфизм

GRA-Zeroing and Lean 4: A Unified Architecture of Verified Self-Stabilizing Intelligence and its Quantum-Informational Isomorphism

Олег

13 октября 2026 г.

Аннотация / Abstract

RU. Современные мультиагентные системы и большие языковые модели подвержены «ловушкам консенсуса»: статистическое большинство может поддерживать внутренне согласованную, но семантически ложную модель. Мы представляем архитектуру GRA (*Gödel–Reductio ad Absurdum*), объединяющую Weighted Partial MaxSAT для пересмотра гипотез и Lean 4 для машинной верификации.

В рамках архитектуры «смерть системы» формализуется как переход в несовместимую, или UNSAT-, область пространства моделей, а «выживание» — как существование допустимой SAT-ревизии, сохраняющей жёсткие ограничения. Мы вводим квантово-информационный изоморфизм между GRA-ревизией и интерпретационными идеями расширенной концепции Эверетта М. Б. Менского. Этот изоморфизм предлагается как исследовательская гипотеза, а не как доказанный физический механизм влияния сознания на квантовые исходы.

Приводятся формальная постановка, воспроизводимый in-silico-тест на основе Weighted Partial MaxSAT, анализ ограничений и практические применения.

EN. Modern multi-agent systems and large language models are susceptible to *consensus traps*: a statistical majority may support an internally consistent but semantically false model. We present the GRA (*Gödel–Reductio ad Absurdum*) architecture, which combines Weighted Partial MaxSAT for hypothesis revision with Lean 4 for mechanized verification.

Within this architecture, *system death* is formalized as a transition to an inconsistent, or UNSAT, region of model space, while *survival* is the existence of an admissible SAT revision preserving hard constraints. We introduce a quantum-informational isomorphism between GRA revision and interpretational ideas of M. B. Mensky's Extended Everett Concept. This isomorphism is proposed as a research hypothesis, not as a proven physical mechanism by which consciousness influences quantum outcomes.

We provide a formal formulation, a reproducible in-silico test based on Weighted Partial MaxSAT, an analysis of limitations, and practical applications.

1 Введение / Introduction

RU

Традиционные подходы к разрешению конфликтов в ИИ — усреднение, дебаты и голосование — часто опираются на синтаксическое согласие. Однако если агенты коррелированно ошибаются,

большинство может поддерживать ложную гипотезу.

GRA вводит **принцип семантической ответственности**: система должна не просто выбирать популярную гипотезу, а проверять её совместимость с жёсткими ограничениями $\mathcal{H}$ и минимизировать ущерб для остальной базы знаний.

Базовый цикл GRA:

$$\text{гипотезы} \to \text{противоречие} \to \text{локализация} \to \text{ревизия} \to \text{верификация}. \tag{1}$$

EN

Traditional approaches to conflict resolution in AI — averaging, debate, and voting — often rely on syntactic agreement. However, if agents fail in a correlated manner, the majority may support a false hypothesis.

GRA introduces the **principle of semantic responsibility**: a system must not merely select a popular hypothesis, but verify its consistency with hard constraints $\mathcal{H}$ and minimize damage to the remaining knowledge base.

The basic GRA cycle is:

$$\text{hypotheses} \to \text{contradiction} \to \text{localization} \to \text{revision} \to \text{verification}. \tag{2}$$

2 Формальная онтология / Formal Ontology

RU

Пусть состояние системы задаётся парой

$$S = (\mathcal{H}, \mathcal{S}),$$

где $\mathcal{H}$ — множество жёстких ограничений, а

$$\mathcal{S} = \{(s_i, w_i)\}_{i=1}^{m}$$

— множество мягких гипотез с весами надёжности $w_i > 0$.

EN

Let the system state be given by the pair

$$S = (\mathcal{H}, \mathcal{S}),$$

where $\mathcal{H}$ is a set of hard constraints and

$$\mathcal{S} = \{(s_i, w_i)\}_{i=1}^{m}$$

is a set of soft hypotheses with reliability weights $w_i > 0$.

Определение 2.1 (Модельная смерть / Model-level death)**.** ***RU.*** *Состояние S называется* модельно мёртвым*, если объединение жёстких и мягких ограничений несовместимо:*

$$\mathcal{H} \cup \mathcal{S} \models \bot. \tag{3}$$

Это определение относится к модели знаний, а не к биологической смерти. Несовместимость формализации означает отсутствие допустимого решения в данной модели, но не доказывает смерть организма или физической системы.

EN. *A state S is called* model-dead *if the union of hard and soft constraints is inconsistent:*

$$\mathcal{H} \cup \mathcal{S} \models \bot. \tag{4}$$

This definition concerns a model of knowledge, not biological death. Inconsistency of a formalization means that the given model has no admissible solution; it does not prove the death of an organism or physical system.

Определение 2.2 (GRA-обнулёнка / GRA-Zeroing)**.** ***RU.*** *GRA-оператор ревизии определяется как*

$$\hat{G}_{\text{MaxSAT}}(\mathcal{H}, \mathcal{S}) = \arg\max_{\mathcal{S}' \subseteq \mathcal{S}} \sum_{(s_i, w_i) \in \mathcal{S}'} w_i \quad \textit{при условии} \quad \mathcal{H} \cup \mathcal{S}' \models \text{SAT}. \tag{5}$$

Эквивалентная формулировка:

$$\mathcal{S}^* = \arg\min_{\mathcal{S}' \subseteq \mathcal{S}} \sum_{(s_i, w_i) \in \mathcal{S} \setminus \mathcal{S}'} w_i \quad \textit{при условии} \quad \mathcal{H} \cup \mathcal{S}' \models \text{SAT}. \tag{6}$$

EN. *The GRA revision operator is defined as*

$$\hat{G}_{\text{MaxSAT}}(\mathcal{H}, \mathcal{S}) = \arg\max_{\mathcal{S}' \subseteq \mathcal{S}} \sum_{(s_i, w_i) \in \mathcal{S}'} w_i \quad \textit{subject to} \quad \mathcal{H} \cup \mathcal{S}' \models \text{SAT}. \tag{7}$$

Equivalently,

$$\mathcal{S}^* = \arg\min_{\mathcal{S}' \subseteq \mathcal{S}} \sum_{(s_i, w_i) \in \mathcal{S} \setminus \mathcal{S}'} w_i \quad \textit{subject to} \quad \mathcal{H} \cup \mathcal{S}' \models \text{SAT}. \tag{8}$$

3 Квантово-информационный изоморфизм / Quantum-Informational Isomorphism

RU

Рассмотрим квантовое состояние

$$|\Psi\rangle = \sum_i c_i |s_i\rangle, \qquad \sum_i |c_i|^2 = 1. \tag{9}$$

После взаимодействия с окружением и декогеренции различные компоненты состояния могут стать практически независимыми по интерференции. В многомировой интерпретации такие компоненты иногда называют ветвями.

GRA-изоморфизм строится по схеме:

$$\text{суперпозиция гипотез} \leftrightarrow \text{множество моделей } \{S^{(1)}, \ldots, S^{(N)}\}, \tag{10}$$

$$\text{декогеренция} \leftrightarrow \text{отбор совместимых моделей}, \tag{11}$$

$$\text{SAT-верификация} \leftrightarrow \text{проекция на допустимое подпространство}. \tag{12}$$

EN

Consider a quantum state

$$|\Psi\rangle = \sum_i c_i |s_i\rangle, \qquad \sum_i |c_i|^2 = 1. \tag{13}$$

After interaction with an environment and decoherence, different components of the state may become practically independent with respect to interference. In the many-worlds interpretation, such components are sometimes called branches.

The GRA isomorphism is constructed as follows:

$$\text{superposition of hypotheses} \leftrightarrow \text{a set of models } \{S^{(1)}, \ldots, S^{(N)}\}, \tag{14}$$

$$\text{decoherence} \leftrightarrow \text{selection of consistent models}, \tag{15}$$

$$\text{SAT verification} \leftrightarrow \text{projection onto an admissible subspace}. \tag{16}$$

Гипотеза 3.1 (Информационное выживание / Informational survival)**.** ***RU.*** *Если в пространстве моделей существует хотя бы одна ревизия $\mathcal{S}'$, такая что*

$$\mathcal{H} \cup \mathcal{S}' \models \mathrm{SAT},$$

то GRA-архитектура способна найти или приблизить такую ревизию и тем самым сохранить непротиворечивость информационной организации.

Эта гипотеза относится к устойчивости модели*, а не к физическому бессмертию. Существование SAT-ревизии не гарантирует выживания организма, личности или субъективного опыта.*

EN. *If there exists at least one revision $\mathcal{S}'$ in model space such that*

$$\mathcal{H} \cup \mathcal{S}' \models \mathrm{SAT},$$

then the GRA architecture can find or approximate such a revision and thereby preserve the consistency of an informational organization.

This hypothesis concerns the stability of a model*, not physical immortality. The existence of a SAT revision does not guarantee the survival of an organism, a person, or subjective experience.*

4 In-silico-верификация / In-Silico Verification

RU

Рассмотрим сценарий «ловушки консенсуса». Пусть имеются два жёстких закона:

$$\mathrm{Heart} \to \mathrm{Oxygen}, \tag{17}$$

$$\neg\mathrm{Oxygen} \to \neg\mathrm{Heart}. \tag{18}$$

Пусть также имеется надёжный внутренний инвариант «сердце бьётся» с весом 100 и двадцать слабых свидетельств от сенсоров с весом 1 каждое, утверждающих отсутствие пульса и кислорода.

MaxSAT ищет назначение истинности, минимизирующее суммарный вес нарушенных мягких ограничений при выполнении всех жёстких:

$$M^* = \arg\min_M \sum_i w_i \mathbf{1}[M \not\models S_i] \quad \text{при условии} \quad M \models \mathcal{H}. \tag{19}$$

Оптимальная ревизия:

$$\mathrm{Heart} = true, \qquad \mathrm{Oxygen} = true, \qquad \mathrm{Sensor_Pulse_0} = false.$$

Цена ревизии:

$$\mathrm{cost} = 20.$$

EN

Consider a *consensus trap*. Let there be two hard laws:

$$\mathrm{Heart} \to \mathrm{Oxygen}, \tag{20}$$

$$\neg\mathrm{Oxygen} \to \neg\mathrm{Heart}. \tag{21}$$

Suppose there is also a reliable internal invariant, “the heart is beating,” with weight 100, and twenty weak sensor reports, each with weight 1, claiming that there is no pulse and no oxygen.

MaxSAT seeks a truth assignment minimizing the total weight of violated soft constraints while satisfying all hard constraints:

$$M^* = \arg\min_M \sum_i w_i \mathbf{1}[M \not\models S_i] \quad \text{subject to} \quad M \models \mathcal{H}. \tag{22}$$

The optimal revision is:

$$\text{Heart} = true, \qquad \text{Oxygen} = true, \qquad \text{Sensor_Pulse_0} = false.$$

The revision cost is:

$$\text{cost} = 20.$$

Listing 1: GRA-Zeroing vs. majority vote in a consensus trap

```
from pysat.formula import WCNF
from pysat.examples.rc2 import RC2

wcnf = WCNF()

# Hard constraints
wcnf.append([-1, 2])    # Heart -> Oxygen
wcnf.append([-2, -1])   # not Oxygen -> not Heart

# Soft constraints
wcnf.append([1], weight=100)

for _ in range(10):
    wcnf.append([3], weight=1)    # no pulse
    wcnf.append([-2], weight=1)   # no oxygen

with RC2(wcnf) as solver:
    model = solver.compute()
    cost = solver.cost

print("Model:", model)
print("Cost:", cost)
```

Ожидаемый результат / Expected output:

$$\texttt{model} = [1, 2], \qquad \texttt{cost} = 20.$$

RU. GRA сохраняет инвариант «сердце бьётся» и отбрасывает противоречащие ему сенсорные данные. Это демонстрирует устойчивость *модели*, а не физическое «квантовое чудо».

EN. GRA preserves the invariant "the heart is beating" and discards the contradictory sensor reports. This demonstrates the stability of a *model*, not a physical "quantum miracle."

5 Ограничения / Limitations

5.1 Границы MaxSAT / Limits of MaxSAT

RU. MaxSAT минимизирует потерю заданных приоритетов. Если веса w_i ошибочны, система может получить внутренне допустимую, но содержательно ложную модель:

$$\mathcal{H} \cup \mathcal{S}^* \models \text{SAT} \quad \not\Rightarrow \quad \mathcal{S}^* \text{ истинна.}$$

EN. MaxSAT minimizes the loss of given priorities. If the weights w_i are wrong, the system may obtain an internally admissible but substantively false model:

$$\mathcal{H} \cup \mathcal{S}^* \models \text{SAT} \quad \not\Rightarrow \quad \mathcal{S}^* \text{ is true.}$$

5.2 Корреляция свидетельств / Correlated evidence

RU. Формула

$$P_{\text{total}} = 1 - \prod_{i=1}^{N}(1 - P_i)$$

верна только для независимых событий. Для коррелированных агентов следует использовать эффективный размер выборки:

$$N_{\text{eff}} = \frac{N}{1 + (N-1)\rho}, \tag{23}$$

где ρ — коэффициент корреляции ошибок. При $\rho \to 1$ имеем $N_{\text{eff}} \to 1$.

EN. The formula

$$P_{\text{total}} = 1 - \prod_{i=1}^{N}(1 - P_i)$$

holds only for independent events. For correlated agents, one should use an effective sample size:

$$N_{\text{eff}} = \frac{N}{1 + (N-1)\rho}, \tag{24}$$

where ρ is the error-correlation coefficient. As $\rho \to 1$, we obtain $N_{\text{eff}} \to 1$.

5.3 Границы Lean 4 / Limits of Lean 4

RU. Lean 4 проверяет, что утверждение следует из заданных аксиом, определений и сертификатов. Он не проверяет соответствие формальной модели физической реальности.

Для SAT-сертификатов корректная схема:

$$\text{SAT-solver} \to \text{DRAT/LRAT certificate} \to \text{Lean 4 verifier}. \tag{25}$$

EN. Lean 4 verifies that a statement follows from given axioms, definitions, and certificates. It does not verify whether a formal model corresponds to physical reality.

For SAT certificates, the correct pipeline is:

$$\text{SAT-solver} \to \text{DRAT/LRAT certificate} \to \text{Lean 4 verifier}. \tag{26}$$

6 Практические применения / Practical Applications

6.1 Отказоустойчивые сети / Fault-tolerant networks

RU. При каскадном сбое датчики могут массово сообщать ложную аварию. GRA-ядро может использовать топологические инварианты сети как жёсткие ограничения и выделять противоречивый набор свидетельств как UNSAT Core.

EN. During a cascading failure, sensors may collectively report a false alarm. A GRA core can use network-topological invariants as hard constraints and identify the inconsistent set of reports as an UNSAT core.

6.2 Верифицируемый ИИ / Verifiable AI

RU. GRA может документировать, какие гипотезы были пересмотрены, почему новая модель допустима и какие утверждения проверены формально.

EN. GRA can document which hypotheses were revised, why the new model is admissible, and which claims have been formally verified.

6.3 Квантовые модели / Quantum models

RU. GRA может проверять корректность квантовых моделей: нормировку состояния, положительную полуопределённость матрицы плотности, сохранение вероятностей и согласованность предсказаний с данными.

Для матрицы плотности

$$\rho = \begin{pmatrix} |\alpha|^2 & \alpha\beta^*\gamma \\ \alpha^*\beta\gamma^* & |\beta|^2 \end{pmatrix}$$

необходимые условия:

$$\operatorname{Tr}\rho = 1, \qquad \rho \succeq 0, \qquad |\gamma| \le 1. \tag{27}$$

EN. GRA can verify the correctness of quantum models: state normalization, positive semidefiniteness of a density matrix, conservation of probabilities, and consistency of predictions with data.

For the density matrix

$$\rho = \begin{pmatrix} |\alpha|^2 & \alpha\beta^*\gamma \\ \alpha^*\beta\gamma^* & |\beta|^2 \end{pmatrix},$$

the necessary conditions are:

$$\operatorname{Tr}\rho = 1, \qquad \rho \succeq 0, \qquad |\gamma| \le 1. \tag{28}$$

7 Заключение / Conclusion

RU. GRA-Обнулёнка, Weighted Partial MaxSAT и Lean 4 образуют прототип архитектуры проверяемого пересмотра гипотез. Она способна формализовать противоречия, выбирать минимальную по заданным приоритетам ревизию и машинно проверять заявленные логические свойства.

Квантово-информационный изоморфизм с идеями М. Б. Менского следует рассматривать как исследовательскую гипотезу. Он может служить источником математических моделей и проверяемых предсказаний, но не доказывает влияния сознания на квантовые вероятности, квантового бессмертия или возможности сознательного выбора ветви.

Главный принцип архитектуры:

$$\boxed{\text{Согласованность} \neq \text{Доказуемость} \neq \text{Эмпирическая истинность.}} \tag{29}$$

EN. GRA-Zeroing, Weighted Partial MaxSAT, and Lean 4 form a prototype architecture for verifiable hypothesis revision. It can formalize contradictions, select a minimal revision under given priorities, and mechanically verify claimed logical properties.

The quantum-informational isomorphism with M. B. Mensky's ideas should be treated as a research hypothesis. It may provide mathematical models and testable predictions, but it does not prove that consciousness influences quantum probabilities, that quantum immortality exists, or that a conscious observer can select a branch.

The central principle of the architecture is:

$$\boxed{\text{Consistency} \neq \text{Provability} \neq \text{Empirical truth.}} \tag{30}$$