GRA-3: Единая архитектура верифицированного самоулучшающегося интеллекта
GRA-3: A Unified Architecture for Verified Self-Improving Intelligence

Abstract

RU. GRA-3 улучшается только внутри допуска, который система способна измерить, верифицировать и безопасно расширять. В отличие от наивной цели полного устранения противоречий, GRA-3 проводит двойную калибровку: адаптирует оценку допустимой пены к реальности и одновременно уменьшает саму пену.

EN. GRA-3 improves only within a tolerance that it can measure, verify, and safely extend. Unlike the naive goal of eliminating all contradictions, GRA-3 performs dual calibration: it adapts its estimate of allowable foam to reality while simultaneously reducing the foam itself.

1 Главный принцип / Core Principle

$$\boxed{\text{GRA improves only within a tolerance} \quad \text{that it can measure and prove.}}$$

$$\boxed{\text{Dual calibration} = \underbrace{\varepsilon_t \to J_t}_{\text{model calibration}} + \underbrace{J_t \to 0}_{\text{foam minimization}}}$$

2 Онтологический слой: Graverce / Ontological Layer: Graverce

2.1 Допустимое состояние / Admissible State

$$\hat{G} : \Omega_M \to \Omega_G, \qquad \Omega_G = \{s \in \Omega_M : J(s) \le \tau\}.$$

2.2 Функционал пены / Foam Functional

$$\boxed{J(s) = \alpha\Phi_C + \beta\Phi_T + \gamma\Phi_V + \delta\Phi_S}$$

Компонент / Component	RU	EN
Φ_C	логические и фактические противоречия	logical and factual contradictions
Φ_T	рассогласование агентов или уровней	disagreement between agents or levels
Φ_V	ошибка верификации	verification error
Φ_S	нестабильность при возмущении	instability under perturbation

Веса $\alpha, \beta, \gamma, \delta$ не являются истиной о мире: это калибруемые приоритеты системы. Их обучение должно быть ограничено конституцией.

3 Двойная калибровка / Dual Calibration

3.1 Калибровка модели допуска / Calibrating the Tolerance Model

$$\boxed{\varepsilon_{t+1} = (1 - \eta_t)\varepsilon_t + \eta_t J_t}$$

$$\boxed{\eta_t = \eta_0 \frac{|J_t - \varepsilon_t|}{|J_t - \varepsilon_t| + c}}$$

3.2 Минимизация пены / Foam Minimization

$$\boxed{\theta_{t+1} = \arg\min_{\theta \in \mathcal{C}} \left[\mathbb{E}[J_{t+1}(\theta)] + \lambda_{\text{deg}}\mathbb{E}[D_t] + \lambda_{\text{safe}}\mathbb{E}[V_t]\right]}$$

где D_t — доля отвергнутых полезных гипотез, V_t — нарушение ограничений безопасности, а $\mathcal{C}$ — конституционные ограничения.

3.3 Баланс целей / Balancing the Objectives

$$\boxed{\mathcal{L}_t = \underbrace{(J_t - \varepsilon_t)^2}_{\text{calibration error}} + \lambda_0 J_t + \lambda_{\text{deg}} D_t + \lambda_{\text{safe}} V_t}$$

$$\boxed{\varepsilon_t \to J_t \quad \text{не означает} \quad J_t \to 0.}$$

4 GRA-шаг / GRA Step

```
Input: state S, parameters theta = (eps, tau, k, w, delta)

1. Measure foam J(S)
2. If J(S) <= tau: return S
3. Localize contradiction sources
4. Generate candidates {S'_1, ..., S'_m}
5. Evaluate J(S'_i) for each candidate
6. Select S_new = argmin J(S'_i)
7. Send S_new to MaxSAT / Lean verification loop
8. Update eps and tau by dual calibration

Output: S_new, or rejection with Human Gate
```

5 Формальный слой / Formal Layer

5.1 Weighted Partial MaxSAT

$$\boxed{F'^{*} = \arg\min_{F' \subseteq \mathcal{S}} \left\{ \sum_{f_i \notin F'} w_i : \mathcal{H} \cup F' \text{ is SAT} \right\}}$$

5.2 MUS как локализация конфликта / MUS as Conflict Localization

$$\boxed{\mathcal{K}^* = \arg\min_{\mathcal{K}\subseteq\Phi} |\mathcal{K}| \quad \text{s.t.} \quad \bigwedge_{\phi\in\mathcal{K}} \phi = \bot}$$

5.3 Lean 4 и LRAT / Lean 4 and LRAT

$$\boxed{\text{Lean} \vdash \text{valid_certificate}(c, F) \Rightarrow \text{Unsatisfiable}(F)}$$

$$\boxed{\text{Repair } \rho \text{ accepted} \iff \text{Lean} \vdash \text{Satisfiable}(\mathcal{H} \cup F'^* \cup \{\rho\})}$$

6 Безопасность и лагранжева калибровка / Safety and Lagrangian Calibration

$$\boxed{\delta_{t+1} = \max\left(\delta_{\min}, \delta_t + \eta_\delta \left[\mathbf{1}[J_t > \tau_t] - \alpha_{\text{target}}\right]\right)}$$

$$\boxed{\tau_t = \varepsilon_t + \delta_t}$$

7 Конституция / Constitution

Параметр / Parameter	Автообновление / Auto-update	Ограничение / Constraint
ε_{GRA}	Да / Yes	$\varepsilon_{\min} \le \varepsilon \le \varepsilon_{\max}$
τ	Да / Yes	$\tau = \varepsilon + \delta,\ \delta \ge \delta_{\min}$
k^*	Да / Yes	$k_{\min} \le k \le k_{\max}$
$\mathbf{w}$	Да / Yes	$w_i \ge 0,\ \sum_i w_i = 1$
δ_{safety}	Вниз — только с подтверждением	$\delta \ge \delta_{\min}$
Hard clauses $\mathcal{H}$	Нет / No	Logic, safety, ethics
Human Gate	Никогда не автоматизируется	Final responsibility

$$\boxed{\mathcal{H}_{\text{ethics}} \text{ is not revised by MaxSAT.}}$$

8 Полный конвейер / Full Pipeline

$$\boxed{\text{Calibration Gate} \to \text{Goal Engine} \to \text{Agent Swarm} \to \text{GRA Critic} \to \text{MaxSAT / MUS} \to \text{Lean 4 Verifier} \to \text{Simula}}$$

9 Верификация in silico / In Silico Verification

$$\varepsilon_{t+1} = (1-\eta)\varepsilon_t + \eta J_t, \qquad \eta = 0.08.$$

$$\delta_{t+1} = \max\left(0.03, \delta_t + 0.05\left[\mathbf{1}[J_t > \tau_t] - 0.05\right]\right).$$

$$\tau_t = \varepsilon_t + \delta_t.$$

$$k_{t+1} = \mathrm{clip}\left[k_t - 0.02\left(0.01(k_t - 0.5) + 0.2\max(0, k_t - 0.7)\right), 0.2, 1.0\right].$$

Метрика / Metric	Начало / Start	Конец / End
Средняя пена J	0.2784	0.0466
Калиброванный допуск ε	—	0.0494
Порог τ	—	0.0877
Средняя ошибка калибровки	—	0.0117
Доля нарушений, последние 100 шагов	—	0.03
Итоговое k	0.5	0.5

$$\boxed{\frac{J_{\text{start}}}{J_{\text{end}}} \approx \frac{0.2784}{0.0466} \approx 5.96.}$$

10 Практические применения / Practical Applications

Область / Domain	GRA-3 action	Guarantee / Гарантия
Наука / Science	hypothesis auditing	formally checked inference
Инженерия / Engineering	digital-twin drift detection	early defect detection
Медицина / Medicine	protocol-model consistency	contradiction flag before clinical use
Финансы / Finance	risk-model reconciliation	auditable decision trail
Робототехника / Robotics	action $\rightarrow$ simulation $\rightarrow$ formal check	constrained-safe behavior
LLM-агенты / LLM agents	swarm meta-control	refusal of unsafe actions

11 Честные границы / Honest Limits

- Weighted Partial MaxSAT является NP-трудной задачей; для больших баз знаний нужны декомпозиция, приближённые решатели и кэширование.
- Не всё формализуется в CNF: ценности, эстетика, контекст и субъективные суждения плохо выражаются клаузами.
- Lean проверяет сертификат, а не мир: корректность вывода не равна полноте или истинности модели.
- Веса могут быть ошибочны: MaxSAT минимизирует взвешенную потерю приоритетов, а не находит объективную истину.
- Стремление к $J = 0$ опасно без ограничителей: оно может уничтожить полезную неопределённость, разнообразие гипотез и способность к обучению.
- Human Gate незаменим: формальная верификация не переносит моральную и институциональную ответственность на машину.

12 Итог / Conclusion

$$\boxed{\text{GRA-3} = \underbrace{\text{Graverce} + \text{Swarm}}_{\text{scale and meaning}} + \underbrace{\text{MaxSAT} + \text{Lean}}_{\text{proof}} + \underbrace{\text{dual calibration}}_{\text{honest self-improvement}} + \underbrace{\text{Human Gate}}_{\text{responsibility}}}$$

$$\boxed{\text{Dual calibration:} \quad \varepsilon_t \to J_t \quad \wedge \quad J_t \to 0 \quad \text{under safety and diversity constraints.}}$$

AI searches. GRA criticizes. MaxSAT minimizes. Lean verifies. Calibration learns twice. Humans remain r