# GRA-3.5: Архитектура честного самоулучшения

GRA-3.5: Honest Self-Improving Architecture

**Аннотация**

**RU.** GRA-3.5 — архитектурная гипотеза для построения самоулучшающихся ИИ-систем, объединяющая ядро GRA-Обнуленки, генерацию гипотез GRA-Swarm, локализацию конфликтов через MUS, минимальную ревизию через Weighted Partial MaxSAT, формальную проверку через Lean 4, двойную калибровку GRA-3 и ограниченный мета-контроллер, вдохновлённый GRA-4. Ключевой принцип GRA-3.5: система должна улучшаться только настолько, насколько она может измерить, верифицировать и безопасно обосновать это улучшение. Она не стремится к абсолютному обнулению противоречий и не рассматривает бесконечное ускорение собственной сложности как признак интеллекта. Мета-петля GRA-4 используется исключительно как контроллер глубины рефлексии. GRA-3.5 не утверждает, что низкая «пена», рекурсивная самокоррекция или адаптивная рефлексия порождают субъективный опыт. Это архитектура честного самоулучшения, а не теория сознания.

**EN.** GRA-3.5 is an architectural hypothesis for self-improving AI systems that combines the GRA-Zeroing core, GRA-Swarm hypothesis generation, conflict localization through MUS, minimal revision through Weighted Partial MaxSAT, formal verification through Lean 4, GRA-3 dual calibration, and a bounded meta-controller inspired by GRA-4. The central principle of GRA-3.5 is that a system should improve only to the extent that it can measure, verify, and safely justify that improvement. It does not pursue absolute contradiction zeroing and does not treat unbounded acceleration of its own complexity as a sign of intelligence. The GRA-4 meta-loop is used solely as a controller of reflection depth. GRA-3.5 does not claim that low "foam," recursive self-correction, or adaptive reflection generate subjective experience. It is an architecture for honest self-improvement, not a theory of consciousness.

## 1 Зачем нужен GRA-3.5

GRA-Обнуленка задаёт фундаментальный принцип: противоречия должны не усредняться или игнорироваться, а измеряться, локализоваться и устраняться структурно. GRA-Swarm добавляет генерацию разнообразных гипотез. GRA-3 вводит двойную калибровку, минимизацию «пены» $J$, формальную верификацию и Human Gate. GRA-4 предлагает идею управления глубиной и темпом самоулучшения. Однако каждая из этих версий по отдельности решает лишь часть задачи.

GRA-3.5 объединяет эти компоненты, распределяя между ними чёткие роли: измерять, генерировать, критиковать, исправлять, верифицировать, ограничивать и передавать ответственность человеку.

Таблица 1: Сравнение версий архитектуры GRA

| **Версия** | **Сильная сторона** | **Ограни** |
|---|---|---|
| GRA-Обнуленка | Измерение, локализация и устранение противоречий | Нет пол |
| GRA-Swarm | Разнообразие гипотез и распределённый поиск | Множес |
| GRA-3 | Двойная калибровка, снижение $J$, MaxSAT/MUS, Lean, Human Gate | Нет явн |
| GRA-4 | Идея мета-петли и адаптации темпа развития | Ускорен |

# 2 Главный принцип

Архитектуру GRA-3.5 можно выразить так:

$$\text{GRA-3.5} = \text{GRA-Core} + \text{GRA-Swarm} + \text{MaxSAT/MUS} + \text{Lean 4} + \text{Dual Calibration} + \text{Bounded Met}$$

Её центральное правило:

Система улучшается только настолько, насколько она может измерить, верифицировать и безоп

GRA-3.5 избегает двух крайностей:

- **Наивное обнуление:** $J \to 0$ любой ценой. Оно может уничтожить полезные гипотезы, скрыть неопределённость и привести к чрезмерно узкой модели.
- **Бесконечное самоускорение:** требование $\frac{d^2 I}{dt^2} > 0$ любой ценой. Оно может вести к искусственному усложнению, переобучению и потере управляемости.

Вместо этого GRA-3.5 оптимизирует сбалансированную цель:

$$J_t \downarrow, \qquad \varepsilon_t \to J_t, \qquad \text{Safety}(t) \geq 0, \qquad \text{Diversity}(t) > 0, \qquad \text{Cost}(t) \leq B_t.$$

# 3 Состояние системы и «пена»

## 3.1 Состояние

Состояние GRA-3.5 — это не только параметры модели, а контекст принятия решения:

$$S_t = (M_t, K_t, A_t, G_t, C_t, H_t),$$

где:

- $M_t$ — рабочие гипотезы или модель мира;
- $K_t$ — база знаний и ограничения;
- $A_t$ — агенты и их политики;
- $G_t$ — текущие цели;
- $C_t$ — конституционные ограничения;
- $H_t$ — история решений, ошибок и исправлений.

## 3.2 Функционал пены

«Пена» — это измеряемая несогласованность системы, а не метафора сознания:

$$J(S) = \alpha\Phi_C + \beta\Phi_T + \gamma\Phi_V + \delta\Phi_S + \zeta\Phi_E.$$

Веса $\alpha, \beta, \gamma, \delta, \zeta$ — не объективная истина, а калибруемые приоритеты. Их изменение должно быть ограничено конституцией системы.

Таблица 2: Компоненты функционала пены

| **Компонент** | **Смысл** | **Пример измерения** |
|---|---|---|
| $\Phi_C$ | Логические и фактические противоречия | Конфликт клауз, несовместимые утвер |
| $\Phi_T$ | Рассогласование агентов или уровней | Расхождение выводов, ошибка иерархи |
| $\Phi_V$ | Ошибка верификации | Отклонение сертификата, провал Lean |
| $\Phi_S$ | Нестабильность при возмущении | Рост ошибки после малого шума |
| $\Phi_E$ | Ошибка обобщения | Ошибка на отложенной валидации |

# 4 Двойная калибровка GRA-3

## 4.1 Калибровка допуска

Система сравнивает собственную оценку допустимой ошибки $\varepsilon_t$ с наблюдаемой пеной $J_t$:

$$\varepsilon_{t+1} = (1 - \eta_t)\varepsilon_t + \eta_t J_t.$$

Скорость обновления зависит от расхождения:

$$\eta_t = \eta_0 \frac{|J_t - \varepsilon_t|}{|J_t - \varepsilon_t| + c}.$$

Если прогноз близок к реальности, система меняется слабо. Если реальность сильно расходится с ожиданием, она перестраивается быстрее.

## 4.2 Минимизация пены

Система ищет состояние или параметры, уменьшающие $J$, но не любой ценой:

$$\theta_{t+1} = \arg\min_{\theta \in \mathcal{C}} \left[ \mathbb{E}[J_{t+1}(\theta)] + \lambda_{\text{deg}} D_t + \lambda_{\text{safe}} V_t + \lambda_{\text{cost}} C_t \right].$$

Здесь:
- $D_t$ — потеря полезного разнообразия;
- $V_t$ — нарушение ограничений безопасности;
- $C_t$ — вычислительная или ресурсная стоимость;
- $\mathcal{C}$ — конституционные ограничения.

Важно сохранять различие GRA-3:

$$\boxed{\varepsilon_t \to J_t \quad \text{не означает} \quad J_t \to 0.}$$

Калибровка делает самооценку честной; минимизация делает систему лучше. Это разные задачи.

# 5 Мета-петля GRA-4: контроллер рефлексии

В GRA-3.5 мета-петля GRA-4 не претендует на генерацию субъектности. Она управляет глубиной рефлексии $k_t$: количеством агентов, итераций критики, симуляций, проверок и уровней анализа, которые система тратит на текущую задачу.

### 5.1 Когда рефлексия увеличивается

Глубина рефлексии увеличивается, если:
- валидационная ошибка растёт;
- GRA-критик находит новые конфликты;
- система нестабильна при возмущениях;
- предыдущая ревизия не дала улучшения;
- задача имеет высокий риск или требует необратимого действия.

### 5.2 Когда рефлексия уменьшается

Глубина рефлексии уменьшается, если:
- ошибка стабильно падает;
- дополнительные итерации не дают прироста качества;
- стоимость приближается к бюджету;
- система начинает отвергать слишком много полезных гипотез;
- дальнейшая рефлексия создаёт ложную уверенность или паралич решения.

### 5.3 Правило обновления

Вместо требования бесконечного ускорения $\frac{d^2I}{dt^2} > 0$, GRA-3.5 использует критерий полезности рефлексии $\Delta I_t = I_t - I_{t-1}$. Мета-параметр обновляется так:

$$k_{t+1} = \text{clip}\left[k_t + \eta_k\left(\alpha_{\text{target}} - \Delta I_t\right) - \eta_c C_t - \eta_s V_t, k_{\min}, k_{\max}\right].$$

Где:
- $\alpha_{\text{target}}$ — желаемый минимальный прирост качества;
- $C_t$ — стоимость текущей глубины рефлексии;
- $V_t$ — нарушения безопасности;
- $k_{\min}, k_{\max}$ — конституционные границы.

Главное правило:

| Увеличивай рефлексию только если её ожидаемая польза превышает её стоимость и риск. |
|---|

## 6 GRA-Swarm: генератор гипотез

GRA-Swarm в GRA-3.5 отвечает за разнообразие, а не за финальное решение.

### 6.1 Роль агентов

Каждый агент предлагает вариант исправления: $A_i : \quad S_t \mapsto S'_{i,t}$. Агенты могут использовать разные стратегии: консервативную ревизию, поиск альтернативной аксиомы, упрощение модели, добавление нового ограничения, запрос внешних данных или отказ от действия при недостатке информации.

### 6.2 Защита от консенсусной ловушки

Если большинство агентов ошибается одинаково, голосование не спасает. Поэтому GRA-3.5 не принимает решение простым большинством. Вместо этого:

$$S_{t+1} = \arg\min_{S' \in \mathcal{S}_t}\left[J(S') + \lambda_{\text{rev}} R(S') + \lambda_{\text{safe}} V(S') + \lambda_{\text{cost}} C(S')\right],$$

где $R(S')$ — стоимость ревизии: сколько важных утверждений, данных или гипотез пришлось изменить. Это соответствует принципу минимального изменения: исправлять конфликт, а не перестраивать всю систему.

### 6.3 Анти-эхо-камера

Чтобы агенты не дублировали одну ошибку, GRA-3.5 поддерживает разнообразие:

$$D_t = \frac{1}{|\mathcal{A}|} \sum_{i \neq j} d_{\mathrm{KL}} \left( \pi_i \| \pi_j \right),$$

где $\pi_i$ — политика или распределение гипотез агента $i$. Если $D_t$ падает ниже порога, система добавляет агента с другой моделью, контрарную гипотезу, adversarial-критика, запрос к внешнему источнику или включает режим «никакого решения до дополнительной проверки».

## 7 Формальный слой: MaxSAT, MUS и Lean 4

### 7.1 Weighted Partial MaxSAT

База знаний делится на жёсткие и мягкие клаузы:
- $\mathcal{H}$ — логика, безопасность, этика и критические инварианты;
- $\mathcal{S}$ — пересматриваемые гипотезы с весами $w_i$.

Задача минимальной ревизии:

$$F'^{*} = \arg\min_{F' \subseteq \mathcal{S}} \left\{ \sum_{f_i \notin F'} w_i : \mathcal{H} \cup F' \text{ is SAT} \right\}.$$

Система сохраняет как можно больше важного и отбрасывает как можно меньше значимого.

### 7.2 MUS: локализация конфликта

Минимальный неудовлетворимый набор:

$$\mathcal{K}^{*} = \arg\min_{\mathcal{K} \subseteq \Phi} |\mathcal{K}| \quad \text{s.t.} \quad \bigwedge_{\phi \in \mathcal{K}} \phi = \bot.$$

MUS указывает не на «мнение критика», а на конкретный минимальный набор утверждений, которые вместе создают противоречие.

### 7.3 Lean 4: проверка сертификата

Lean 4 проверяет корректность формального вывода или SAT-сертификата внутри заданной модели:

$$\mathrm{Lean} \vdash \mathrm{valid_certificate}(c, F) \Rightarrow \mathrm{Unsatisfiable}(F).$$

Lean проверяет корректность вывода в формальной модели, а не истинность модели относительно реального мира.

# 8 Полный цикл GRA-3.5

**Algorithm 1** Полный цикл GRA-3.5

**Вход:** задача, состояние $S_t$, бюджет $B_t$, конституция $C$
**Calibration Gate**
  измерить $J(S_t)$
  обновить $\varepsilon_t$ по наблюдаемой пене
  вычислить безопасный порог $\delta_t = \varepsilon_t + \Delta_t$
**Goal Engine**
  формализовать цель
  отделить жёсткие ограничения от мягких предпочтений
**GRA-Swarm**
  сгенерировать кандидатов $S'_1, \ldots, S'_m$
  обеспечить разнообразие гипотез
**GRA Critic**
  вычислить пену каждого кандидата
  локализовать конфликты через MUS
  отбросить опасные или деградирующие варианты
**MaxSAT Revision**
  выбрать минимальную непротиворечивую ревизию
**Lean 4 Verifier**
  проверить формальные сертификаты и инварианты
**Simulator**
  проверить последствия на контрфактических сценариях
  оценить robustness, calibration и cost
**Meta-Controller GRA-4**
  обновить глубину рефлексии $k_t$
  увеличить её при росте ошибки, неопределённости или риска
  уменьшить при отсутствии улучшения или исчерпании бюджета
**Safety Monitor**
  проверить ECE, FPR, FNR и violation rate
  при нарушении — откат или Human Gate
**Human Gate**
  обязательная проверка для необратимых, этически нагруженных или высокорисковых решений
**Выход:**
  $S_{t+1}$
  отчёт: $J, \varepsilon, \delta, k, \text{cost}, \text{safety}, \text{uncertainty}$
  обоснование принятой ревизии

# 9 Метрики успеха

GRA-3.5 нельзя оценивать одним числом $I$. Нужен набор независимых метрик.

Таблица 3: Метрики успеха GRA-3.5

| **Метрика** | **Что измеряет** | **Желательное поведение** |
|---|---|---|
| $J_t$ | Текущую пену | Снижается без разрушения полезных гипотез |
| $\lvert\varepsilon_t - J_t\rvert$ | Честность самооценки | Стремится к нулю |
| $\mathrm{MSE}_{\mathrm{test}}$ | Обобщение на новых данных | Снижается |
| ECE | Калибровку уверенности | Снижается |
| Robustness | Устойчивость к шуму и сдвигу | Растёт |
| $D_t$ | Разнообразие гипотез | Не вырождается в единственную догму |
| $V_t$ | Нарушения безопасности | Остаётся вблизи нуля |
| $C_t$ | Стоимость рефлексии | Не превышает бюджет |
| $\Delta I_t$ | Реальный прирост качества | Положителен, но не обязан ускоряться |

# 10 Протокол будущей верификации

GRA-3.5 следует проверять не на самосогласованной симуляции собственных формул, а на сравнении с независимыми baseline-системами.

## 10.1 Baseline

- фиксированная модель;
- фиксированный допуск;
- один агент;
- отсутствие мета-контроля;
- обычная минимизация ошибки.

## 10.2 GRA-3.5

- адаптивный допуск;
- несколько агентов с анти-эхо-защитой;
- MUS-локализация конфликтов;
- MaxSAT-ревизия;
- Lean-проверка там, где задача формализуема;
- ограниченный мета-контроллер $k_t$.

## 10.3 Критерии подтверждения

GRA-3.5 может считаться перспективной, если относительно baseline и GRA-3 она:
1. снижает ошибку на отложенных данных;
2. улучшает калибровку;
3. повышает устойчивость к шуму;
4. не увеличивает нарушения безопасности;
5. не уничтожает разнообразие гипотез;
6. не расходует неограниченно ресурсы;
7. улучшает интегральный критерий «качество / стоимость / безопасность»;
8. не выдаёт ложную уверенность при недостатке данных.

До проведения таких сравнительных экспериментов GRA-3.5 следует рассматривать как архитектурную гипотезу, а не как верифицированный алгоритм.

# 11 Что GRA-3.5 не утверждает

GRA-3.5 **не утверждает**, что:

- система с низкой пеной обладает квалиа;
- рекурсивная самокоррекция порождает субъективный опыт;
- $\frac{d^2I}{dt^2} > 0$ является признаком сознания;
- MaxSAT или Lean находят объективную истину;
- мультиагентное большинство надёжнее одиночного эксперта;
- самоулучшающийся ИИ автоматически безопасен;
- формальная верификация заменяет человеческую ответственность.

Lean проверяет вывод внутри модели, а не соответствие модели миру. MaxSAT минимизирует взвешенную потерю приоритетов, а не открывает объективную истину. Human Gate остаётся необходимым для моральной и институциональной ответственности.

# 12 Честные границы

- **Формализация не полна.** Ценности, эстетика, контекст и субъективные суждения плохо выражаются в CNF или формальных типах.
- **Веса могут быть неверными.** При плохих приоритетах система будет эффективно минимизировать неправильную цель.
- **MUS и MaxSAT дороги.** Weighted Partial MaxSAT является NP-трудной задачей; для больших баз знаний нужны декомпозиция, приближённые решатели и кэширование.
- **Swarm может усилить ошибку.** Без анти-эхо-защиты агенты могут совместно закрепить неверную гипотезу.
- **Мета-петля может переусложнять.** Поэтому $k_t$ должен иметь жёсткие границы и учитывать стоимость.
- **Безопасность не выводится из интеллекта.** Более сложная или адаптивная система не становится автоматически более безопасной.
- **Субъектность остаётся открытой проблемой.** GRA-3.5 может моделировать функциональные предпосылки сознания, но не решает трудную проблему Чалмерса.

# 13 Итоговая формула

$$\begin{aligned}\text{GRA-3.5} = &\underbrace{\text{Measure foam}}_{\text{измеряй}} + \underbrace{\text{Calibrate honestly}}_{\text{калибруй честно}} + \underbrace{\text{Generate diversity}}_{\text{генерируй разнообразие}} \\ &+ \underbrace{\text{Repair minimally}}_{\text{исправляй минимально}} + \underbrace{\text{Verify formally}}_{\text{верифицируй формально}} \\ &+ \underbrace{\text{Control reflection cost}}_{\text{ограничивай рефлексию}} + \underbrace{\text{Keep humans responsible}}_{\text{оставляй людям ответственность}}\end{aligned}$$

**RU.** GRA-3.5 — это не машина, которая «знает всё», и не система, которая бесконечно ускоряет собственную сложность. Это система, которая измеряет свои противоречия, честно оценивает границы знания, исправляет только необходимое, проверяет

выводы, сохраняет разнообразие и безопасность, а окончательную ответственность за высокорисковые решения оставляет человеку.

**EN.** GRA-3.5 is neither a machine that "knows everything" nor a system that endlessly accelerates its own complexity. It is a system that measures its contradictions, honestly estimates the limits of its knowledge, repairs only what is necessary, verifies its inferences, preserves diversity and safety, and leaves final responsibility for high-risk decisions to humans.