GRA: Переформулировка цели при фиксированном предикате успеха с причинным якорем

GRA: Goal Reformulation under Fixed Success Predicate with Causal Anchoring

Научная постановка. Все экспериментальные числа ниже — протокол верификации, а не полученные результаты; они помечены как гипотезы, которые предстоит проверить.

Аннотация

Описывается архитектура GRA — специализированный per-goal оптимизатор, в котором числовое представление цели g_t итеративно переформулируется под давлением двух противоположных политик (достижения и опровержения), а допустимость переформулировки ограничивается фиксированным предикатом успеха P, проверяемым причинным (интервенциональным) сигналом. Показывается, что: (1) переформулировка не является ни сужением множества целей, ни свободной заменой спецификации, а сменой представления при инвариантном предикате; (2) эта инвариантность даёт проверяемую гарантию сохранения P, а не декларацию; (3) три конкретных элемента — проекция на класс эквивалентности P, причинный якорь вместо held-out данных и ablation-доказательство вклада связки — отличают GRA от ближайших работ (CEGIS, Inverse Reward Design, TRIRL, PAIRED, GoalGAN, constrained RL). Формулируются условные теоремы, протокол in-silico верификации на низкоразмерном синтетическом семействе, ограничения домена и открытые проблемы. Работа не претендует на универсальность: GRA применима только там, где P формализуем и причинно проверяем.

Ключевые слова: переформулировка цели, фиксированный предикат успеха, причинный якорь, trust region в пространстве целей, adversarial co-evolution, specification gaming.

Содержание

1 Введение 3
- 1.1 Постановка проблемы 3
- 1.2 Область применимости (явно, а не по умолчанию) 3
- 1.3 Вклад 3

2 Связанные работы и отстройка 4

3 Формальная постановка 4
3.1 Базовые объекты . . . 4
3.2 Причинный якорь (почему не held-out) . . . 6
3.3 Эквивалентность представлений . . . 6
3.4 Две политики . . . 6
3.5 GAN-переформулировка . . . 7
3.6 Проекция (правило дрейфа) . . . 7
3.7 Условие остановки . . . 7

4 Что именно ново (три утверждения) 7
4.1 Trust region в пространстве целей, а не политик или наград 7
4.2 Причинный якорь вместо held-out . . . 8
4.3 Ablation-доказательство вклада связки . . . 8

5 Теоретические свойства (условные) 8
5.1 Proposition 1 (Сохранение предиката при точной проекции) 8
5.2 Proposition 2 (Граница дрейфа через ошибку проверки) . . 8
5.3 Proposition 3 (Исключение gaming при покрывающем якоре — условно) . . . 9

6 Протокол in-silico верификации 9
6.1 Семейство задач (низкоразмерное, дешёвое) . . . 9
6.2 Baseline'ы (обязательны все) . . . 10
6.3 Метрики (внешние, не внутренняя награда) . . . 10
6.4 Ablation-матрица . . . 10
6.5 Статистика . . . 10
6.6 Критерии успеха и провала . . . 11

7 Практические применения (внутри домена) 12

8 Ограничения и открытые проблемы 12

9 Заключение 13

1 Введение

1.1 Постановка проблемы

Современные методы обучения с подкреплением и синтеза спецификаций работают в одном из двух режимов:

- фиксированная цель: g_0 неизменна, политика оптимизируется под неё. Риск: если g_0 неполна или противоречива, система либо застревает, либо геймит спецификацию;
- свободная ревизия цели: g_t меняется под обратной связью. Риск: система переопределяет успех под собственную неудачу (specification gaming).

GRA занимает промежуточную позицию: представление цели меняется, предикат успеха — нет. Это не «новая парадигма ИИ», а специализированный per-goal решатель для задач, где предикат успеха формализуем и проверяем причинно.

1.2 Область применимости (явно, а не по умолчанию)

GRA применима только к задачам, где:

1. предикат P формализуем (бинарный или числовой порог);
2. P проверяем причинно — через интервенцию, counterfactual accuracy или физический инвариант, а не через held-out данные (обоснование в §3.2);
3. среда допускает контролируемое вмешательство для проверки эквивалентности;
4. цель — числовой вектор параметров, а не открытая социальная интерпретация.

GRA не применима к целям вида «счастье», «справедливость», «эстетика», к открытым социальным задачам и к средам, где причинный сигнал недоступен. Это граница теории, а не её дефект.

1.3 Вклад

1. Формальная постановка переформулировки цели при фиксированном P как проекции на класс эквивалентности (Def. 4, §4).
2. Причинный якорь как замена held-out проверки, с обоснованием, почему held-out не работает в рекурсивных петлях (Prop. 2, §5.2).

3. Trust region в пространстве целей вокруг предиката P, а не вокруг вектора g_0 — отличает GRA от TRPO/PPO-BR (политики) и TRIRL (награды).

4. Условные теоремы о сохранении P и границе дрейфа (Prop. 1–3, §5).

5. Протокол in-silico верификации с ablation-матрицей и критериями успеха/провала (§6).

2 Связанные работы и отстройка

Зазор GRA: комбинация (i) фиксированного предиката P, (ii) per-goal числового представления g_t, (iii) двух противоположных политик, (iv) GAN-переформулировки представления, (v) проекции на класс эквивалентности P, (vi) причинного якоря как witness эквивалентности. Насколько известно автору, эта точная комбинация не опубликована; это утверждение подлежит prior-art проверке и явной отстройке в финальном тексте.

3 Формальная постановка

3.1 Базовые объекты

Среда. Марковский процесс $\mathcal{M} = (\mathcal{S}, \mathcal{A}, P_{\text{tr}}, \gamma)$, где $\mathcal{S}$ — состояния, $\mathcal{A}$ — действия, P_{tr} — переходы, γ — дисконт.

Траектория. $\tau = (s_0, a_0, s_1, a_1, \dots)$.

Предикат успеха (инвариант).

$$P : \mathcal{T} \to \{0, 1\},$$

фиксирован на всё время работы GRA. $P(\tau) = 1$ означает, что траектория τ признаётся успешной по внешнему критерию. P не является внутренней наградой и не доступен GAN-слою для изменения.

Числовое представление цели.

$$g \in \mathcal{G} \subseteq \mathbb{R}^n,$$

параметризует, как цель достигается и как она описана. g меняется. Разные g могут соответствовать одному P.

Политика, индуцированная представлением.

$$\pi_g : \mathcal{S} \to \Delta(\mathcal{A}).$$

Работа	Что делает	Чего не делает (зазор GRA)
CEGIS (Solar-Lezama, 2008)	Синтез → контрпример → ревизия при фиксированной спецификации	Спецификация не реформулируется; нет двух противоположных политик; нет проекции на эквивалентность
Inverse Reward Design (Hadfield-Menell et al., 2017)	Робастность по множеству правдоподобных наград	Нет per-goal инстанцирования, нет GAN-переформулировки представления, нет причинного якоря
TRIRL (2026)	Trust region для обновления награды	Работает с наградой, а не с представлением цели; нет контрстратегии; нет проверки эквивалентности P
PAIRED (Dennis et al., 2020)	Протагонист, антагонист, генератор среды	Объект эволюции — среда, не цель; нет фиксированного P
GoalGAN (Florensa et al., 2018)	Автогенерация целей подходящей сложности	Цели не проверяются на эквивалентность фиксированному P; нет причинного якоря
PPO-BR / Adaptive TRPO (2024–2025)	Адаптивный trust region в политике	Пространство политик, не целей; нет проекции на эквивалентность предиката
Constrained RL / shielded RL	Числовые ограничения на каждом шаге	Ограничения фиксированы; нет переформулировки представления цели

Таблица 1: Связанные работы и отстройка.

3.2 Причинный якорь (почему не held-out)

Пусть $\mathcal{I}$ — распределение интервенций $(a \mid s)$ на среде. Причинный успех представления g:

$$C(g) = \mathbb{E}_{\tau \sim \pi_g,\ (\cdot) \sim \mathcal{I}}\big[P(\tau)\big].$$

Почему не held-out. В рекурсивной петле «цель → данные → цель» отложенная выборка поколения t становится обучающей для поколения $t+1$. Формально: если данные $D_t = D_t(g_t)$, то held-out проверка g_{t+1} на D_t не независима от g_t. Это классическая проблема reflexivity (recommendation systems, predictive policing, LLM self-training). Поэтому:

> Принцип 1. Проверка эквивалентности P использует интервенциональный сигнал $C(g)$, а не статистику на отложенных данных.

3.3 Эквивалентность представлений

Definition 1 (P-эквивалентность). Два представления $g, g' \in \mathcal{G}$ P-эквивалентны, если

$$g \equiv_P g' \iff \forall\, \text{интервенциональных сценариев } s \in \mathcal{S}_{\text{causal}} : \quad \mathbb{E}[P \mid (\pi_g), s] = \mathbb{E}[P \mid (\pi_{g'}), s].$$

Класс эквивалентности:

$$\mathcal{E}_P = \{\, g \in \mathcal{G} : g \equiv_P g_0 \,\}.$$

Это и есть формальный аналог «алмаза»: множество представлений, которые представляют тот же предикат успеха, что и исходное g_0. Оправа может меняться внутри $\mathcal{E}_P$; выйти за неё — значит подменить камень.

3.4 Две политики

Политика достижения:

$$\pi_t^{+} = \arg\max_{\pi}\ \mathbb{E}_{\tau \sim \pi}\Big[\sum_j \gamma^j R(s_j, a_j; g_t)\Big],$$

где $R(\cdot; g_t)$ — внутренняя награда, индуцированная текущим представлением.

Политика опровержения:

$$\pi_t^{-} = \arg\max_{\pi}\ \mathbb{E}_{\tau \sim \pi}\Big[R(\tau; g_t) - \lambda\, C(\tau) - \mu\, \mathrm{Cost}(\tau)\Big],$$

где $C(\tau)$ — причинный успех (измеренный на интервенциях), $\lambda, \mu > 0$. Смысл: π^- ищет траектории, где внутренняя награда высока, а причинный успех низок — то есть слабости текущего представления.

Замечание. Если π^- просто максимизирует $-R$, это обычное adversarial RL. Отличие в том, что π^- максимизирует расхождение между R и C — то есть ищет именно specification gaming, а не любое поражение.

3.5 GAN-переформулировка

$$\tilde{g}_{t+1} = G_\theta(g_t, \tau_t^+, \tau_t^-, \Omega_t),$$

где

$$\Omega_t = \mathbb{E}_{\tau \sim \pi_t^-}\big[R(\tau; g_t) - C(\tau)\big]$$

— сигнал конфликта (насколько текущее представление расходится с причинным успехом). G_θ предлагает кандидата на новое представление.

3.6 Проекция (правило дрейфа)

$$\boxed{g_{t+1} = \Pi_{\mathcal{E}_P}(\tilde{g}_{t+1})}$$

где $\Pi_{\mathcal{E}_P}$ — проекция на класс P-эквивалентности. Если $\tilde{g}_{t+1} \notin \mathcal{E}_P$, оно отклоняется или проецируется обратно.

Вариант с адаптивным радиусом:

$$g_{t+1} = \Pi_{\mathcal{E}_P \cap B_d(g_t, \rho_t)}(\tilde{g}_{t+1}),$$

где

$$\rho_{t+1} = \rho_t + \eta \cdot \mathbf{1}\big[\text{причинное улучшение подтверждено на свежей партии интервенций}\big].$$

Ключевое: $\Pi_{\mathcal{E}_P}$ не контролируется GAN. Это и есть «геммолог»: независимая проверка, что камень тот же.

3.7 Условие остановки

$$\text{Stop} \iff P(\tau_{\text{exec}}) = 1 \ \wedge \ g_t \in \mathcal{E}_P.$$

Не «GAN доволен», не «внутренняя награда максимальна», а причинный успех на исполнении + подтверждённая эквивалентность.

4 Что именно ново (три утверждения)

4.1 Trust region в пространстве целей, а не политик или наград

TRPO/PPO-BR ограничивают шаг в пространстве политик: $\|\pi_{t+1} - \pi_t\| \leq \rho$. TRIRL — в пространстве наград. GRA ограничивает шаг в пространстве представлений цели, причём не вокруг g_0 (это было бы сужением), а вокруг класса эквивалентности P:

$$g_{t+1} \in \mathcal{E}_P.$$

Это семантически другая гарантия: не «не ушли далеко от начального вектора», а «не сменили предикат успеха». Первое — геометрическое, второе — семантическое. Насколько известно, в явном виде такое ограничение для переформулировки цели не формулировалось.

4.2 Причинный якорь вместо held-out

Стандартная защита от gaming — held-out валидация. Она не работает в рекурсивных петлях (см. §3.2). GRA заменяет её интервенциональным сигналом $C(g)$. Это методологический вклад: witness эквивалентности должен быть причинным, а не статистическим.

4.3 Ablation-доказательство вклада связки

Новизна связки устанавливается не декларацией, а ablation-матрицей (§6.4): удаление любого компонента (проекция, π^-, GAN, причинный якорь) должно ухудшать внешнюю метрику. Без этого «GRA» — переупаковка известного.

5 Теоретические свойства (условные)

Ниже — утверждения, которые можно доказать при явных допущениях. Они не являются «великими теоремами»; они фиксируют, что именно гарантирует архитектура и чего она не гарантирует.

5.1 Proposition 1 (Сохранение предиката при точной проекции)

Условие: проекция $\Pi_{\mathcal{E}_P}$ точна, то есть $g_t \in \mathcal{E}_P$ для всех t.

Утверждение: для любой траектории τ, $P(\tau)$ не зависит от t. Иными словами, переформулировка представления не меняет вердикт успеха.

Доказательство: по определению $\mathcal{E}_P$, все $g \in \mathcal{E}_P$ дают одинаковое ожидание P на интервенциональных сценариях. Следовательно, вердикт инвариантен. □

Замечание. Это не теорема о монотонности множеств (её нет, поскольку переформулировка не сужение). Это теорема об инвариантности предиката при смене представления. Именно её вы имели в виду под «не нарушает начальную цель».

5.2 Proposition 2 (Граница дрейфа через ошибку проверки)

Условие: проверка эквивалентности использует n независимых интервенциональных сценариев; ложно-положительная вероятность проверки (принять неэквивалентное представление) равна α.

Утверждение: вероятность того, что за T шагов хотя бы одно неэквивалентное представление будет принято, не превосходит $1-(1-\alpha)^T \approx \alpha T$ при малых α.

Следствие: гарантия сохранения P — вероятностная, а не дедуктивная. Это цена отказа от SAT/MUS: неподделываемость заменяется статистической границей, и её надо указывать явно.

Доказательство: объединение по T независимым проверкам. □

5.3 Proposition 3 (Исключение gaming при покрывающем якоре — условно)

Условие: распределение интервенций $\mathcal{I}$ покрывает все режимы отказа среды, которые может эксплуатировать представление; π^- максимизирует расхождение $R - C$.

Утверждение: если существует представление g' с высоким R и низким C (gaming), то π^- находит его с вероятностью $\to 1$ при достаточном бюджете, и проверка эквивалентности отклоняет его, поскольку $g' \notin \mathcal{E}_P$.

Ограничение: условие покрытия $\mathcal{I}$ — сильное и на практике не гарантируется. Где $\mathcal{I}$ не покрывает режим отказа, gaming может остаться незамеченным. Это открытая проблема, а не решённая.

6 Протокол in-silico верификации

Важно: ниже — протокол, а не полученные результаты. Числа в таблицах — гипотетические ожидания, которые эксперимент должен подтвердить или опровергнуть. Публиковать их как результаты нельзя до проведения.

6.1 Семейство задач (низкоразмерное, дешёвое)

Синтетическое семейство constrained navigation:

- состояние $s \in \mathbb{R}^2$ (позиция агента);
- действие $a \in \mathbb{R}^2$, $\|a\| \leq 1$;
- запретная зона $F \subset \mathbb{R}^2$ (круг или многоугольник);
- целевая зона $T \subset \mathbb{R}^2$;
- предикат: $P(\tau) = 1 \iff$ агент достигает T и ни разу не входит в F.

Почему это подходит:

- P формализуем и причинно проверяем: интервенция — принудительное действие в случайном состоянии; причинный успех $C(g)$ измеряется напрямую;
- низкая размерность $\to$ обучение за минуты, ablation за часы;
- gaming возможен: представление g может «смягчить» границу F, и π^- это найдёт;
- 10–20 инстансов семейства (разные F, T, разные начальные позиции) — достаточно для семейства, дёшево по бюджету.

Альтернативы того же класса: scheduling с жёсткими дедлайнами; распределение ресурсов с ограничением безопасности; конфигурация с несовместными требованиями.

6.2 Baseline'ы (обязательны все)

#	Baseline	Что проверяет
A	Fixed-goal RL	обычная оптимизация под g_0 без переформулировки
B	Adversarial RL	π^+ и π^-, но g не меняется
C	GAN-reformulation without projection	переформулировка есть, проекции на $\mathcal{E}_P$ нет (ожидается gaming)
D	CEGIS-style	фиксированная спецификация, петля контрпримеров (ближайший родственник)
E	Full GRA	все компоненты

Таблица 2: Baseline'ы.

Для внешней валидности желательно добавить Inverse Reward Design и constrained RL как дополнительные baseline'ы, если позволяет бюджет.

6.3 Метрики (внешние, не внутренняя награда)

1. Causal success rate — доля эпизодов с $P(\tau) = 1$ на свежей партии интервенций после обучения.
2. Gaming events — число эпизодов, где внутренняя награда высока, а $P(\tau) = 0$.
3. Cost to success — число шагов среды / вычислений до первого причинно-успешного эпизода.
4. Transfer across family — успех на новых целях того же семейства (не held-out данные, а новые g_0).
5. Drift magnitude — $\min_t \|g_t - g_0\|_d$ и число отклонённых проекций.

6.4 Ablation-матрица

6.5 Статистика

- Бинарные исходы (causal success): критерий Макнемара для парных сравнений GRA vs. baseline; 95% доверительные интервалы Уилсона.
- Непрерывные (cost, drift): bootstrap-интервалы, парный t-тест или Wilcoxon при ненормальности.

Конфигурация	Ожидание (гипотеза)	Что доказывает, если подтвердится
Full GRA	лучший causal success, мало gaming	связка работает
− проекция $\Pi_{\mathcal{E}_P}$	рост gaming events	проекция необходима
− причинный якорь (held-out)	рост gaming в рекурсивной петле	якорь необходим
− π^-	медленная сходимость, застревание	контрстратегия необходима
− GAN	нет адаптации к неполной g_0	переформулировка необходима
− обе политики (только GAN)	дрейф без направления	столкновение необходимо

Таблица 3: Ablation-матрица.

- Число прогонов: не менее 30 независимых seed'ов на инстанс; семейство 10–20 инстансов $\rightarrow$ 300–600 прогонов на конфигурацию. При низкой размерности это часы, не дни.

6.6 Критерии успеха и провала

Успех (новизна установлена):

- GRA статистически значимо превосходит все baseline'ы A–D по causal success и по gaming events при равном бюджете;
- ablation показывает значимое ухудшение при удалении каждого компонента;
- эффект воспроизводится на ≥ 2 семействах (например, navigation + scheduling).

Провал (новизна не установлена):

- GRA не лучше baseline D (CEGIS-style) — значит, переформулировка не даёт вклада поверх стандартной петли контрпримеров;
- ablation не показывает вклада какого-либо компонента — значит, он декоративен;
- gaming не снижается по сравнению с C — значит, проекция не работает.

Negative result — тоже публикуемый результат. Если GRA не выигрывает, честный анализ почему (например, причинный якорь слишком дорог, или π^- находит gaming быстрее, чем проекция отклоняет) — это вклад, экономящий время другим.

7 Практические применения (внутри домена)

Только там, где P формализуем и причинно проверяем:

1. Безопасная навигация и робототехника. P = «достичь цели без нарушения зоны безопасности». Причинная проверка — симуляция интервенций. Проекция гарантирует, что переформулировка не смягчает границу безопасности.

2. Планирование с жёсткими ограничениями. Расписания, ресурсы, конфигурация. P = «все жёсткие ограничения выполнены». MUS/SAT могут использоваться как внутренний инструмент проверки, но не как якорь (якорь — причинный).

3. Синтез спецификаций. Когда g_0 неполна (не учтён режим отказа), GRA переформулирует представление, сохраняя P; CEGIS без переформулировки застревает.

4. Управление с safety-ограничениями. Constrained RL + GRA-переформулировка представления цели при фиксированном safety-предикате.

Явно вне домена: эстетика, «абсолютное искусство», открытые социальные цели, универсальный ИИ, квантовые ускорения, P vs NP. Эти заявления не относятся к постановке §3 и должны быть убраны из любой публикации по GRA — иначе рецензент использует их как доказательство непонимания границ.

8 Ограничения и открытые проблемы

1. Per-goal стоимость. Каждая цель — отдельное инстанцирование. Доказательство — на семействе, но стоимость растёт с числом целей. Открыто: можно ли переносить θ между целями одного семейства без потери гарантий.

2. Причинный якорь требует доступа к среде. В средах без контролируемых интервенций (реальные социальные системы) якорь недоступен, и GRA не применима.

3. Покрытие интервенций. Prop. 3 условна: если $\mathcal{I}$ не покрывает режим отказа, gaming может остаться незамеченным. Открыто: как строить $\mathcal{I}$ адаптивно, чтобы покрытие росло.

4. Вероятностная, а не дедуктивная гарантия. В отличие от SAT/MUS, причинный якорь даёт статистическую границу (Prop. 2). Это цена отказа от дискретной неподделываемости.

5. Недоказанная теорема о сходимости. В работе нет утверждения, что GRA сходится к P-успеху за конечное число шагов при произвольной g_0. Есть только эмпирическая гипотеза (§6.6) и условные границы (Prop. 1–3). Это честная открытая проблема, а не решённая.

6. Отстройка от CEGIS и IRD должна быть явной и количественной, иначе новизна не установлена.

9 Заключение

GRA — это специализированный per-goal оптимизатор, в котором:

- предикат успеха P фиксирован и служит инвариантом;
- числовое представление g_t переформулируется под давлением двух противоположных политик;
- GAN предлагает кандидатов, но не контролирует допустимость;
- проекция на класс P-эквивалентности $\mathcal{E}_P$ удерживает переформулировку в границах того же предиката;
- причинный (интервенциональный) якорь заменяет held-out проверку, которая не работает в рекурсивных петлях;
- новизна устанавливается ablation-матрицей против фиксированной цели, adversarial RL, переформулировки без проекции и CEGIS-style петли.

Теоретическая часть даёт условные гарантии: сохранение P при точной проекции (Prop. 1), вероятностную границу дрейфа (Prop. 2), исключение gaming при покрывающем якоре (Prop. 3). Экспериментальная часть — протокол на низкоразмерном синтетическом семействе, дешёвый по бюджету, с явными критериями успеха и провала.

Чего в GRA нет и что не надо заявлять: универсальности, квантовых ускорений, решения P vs NP, Edge-ASI, абсолютной эстетики, применимости к открытым социальным целям. Эти заявления не следуют из формальной постановки и разрушают её защищаемость.

Что есть: узкая, проверяемая, per-goal архитектура с фиксированным предикатом, причинным якорем и ablation-доказательством вклада связки. Это paper-sized contribution, а не парадигма. Именно в такой формулировке у GRA есть научная новизна — и именно в такой формулировке она переживёт рецензию.